

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Tăng Sênh Mạnh - 22120202

Đỗ Tiến Mạnh - 22120203

**PHÁT HIỆN RANH GIỚI CẢNH QUAY
DỰA TRÊN MÔ HÌNH HỌC SÂU**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHÍNH QUY

GIÁO VIÊN HƯỚNG DẪN

TS. Trần Thái Sơn

Tp. Hồ Chí Minh, tháng 04/2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan đây là công trình nghiên cứu của nhóm tác giả. Các số liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với các đề tài khác.

LỜI CẢM ƠN

Nhóm tác giả xin gửi lời cảm ơn chân thành và sâu sắc đến TS. Trần Thái Sơn, giảng viên hướng dẫn đề tài, người đã tận tình định hướng, theo sát quá trình thực hiện và đưa ra những góp ý quý báu để nhóm hoàn thiện nghiên cứu. Sự hỗ trợ của thầy không chỉ giúp nhóm tháo gỡ các khó khăn về chuyên môn mà còn giúp nhóm rèn luyện cách tiếp cận vấn đề một cách nghiêm túc và có hệ thống.

Nhóm cũng xin trân trọng cảm ơn Ban lãnh đạo, quý thầy cô giảng viên và cán bộ nhân viên ngành Công nghệ thông tin đã tạo điều kiện thuận lợi trong suốt quá trình học tập, nghiên cứu và thực hiện đề tài. Những kiến thức, kinh nghiệm và sự hỗ trợ từ quý thầy cô là nền tảng quan trọng để nhóm có thể vận dụng vào quá trình xây dựng, thử nghiệm và hoàn thiện nội dung nghiên cứu.

Bên cạnh đó, nhóm xin gửi lời cảm ơn đến gia đình, anh chị và bạn bè đã luôn động viên, chia sẻ và đóng góp ý kiến trong thời gian thực hiện đề tài. Sự đồng hành và khích lệ của mọi người là nguồn động lực lớn giúp nhóm kiên trì hoàn thành công việc.

Mặc dù đã nỗ lực hoàn thiện báo cáo trong khả năng tốt nhất, nhóm tác giả nhận thức rằng nội dung vẫn khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được sự góp ý của quý thầy cô để đề tài được hoàn thiện hơn. Kính chúc quý thầy cô nhiều sức khỏe, hạnh phúc và thành công trong công tác giảng dạy, nghiên cứu.

Xin chân thành cảm ơn!

ĐỀ CƯƠNG CHI TIẾT

Đề cương chi tiết của khóa luận được tóm lược như sau:

1. **Bối cảnh nghiên cứu:** sự bùng nổ của video ngắn làm gia tăng nhu cầu phân đoạn video theo thời gian một cách tự động và chính xác.
2. **Bài toán đặt ra:** xác định ranh giới giữa các shot trong video, bao gồm cả chuyển cảnh đột ngột và chuyển cảnh dần dần.
3. **Khó khăn chính:** nhịp cắt nhanh, nội dung biến đổi mạnh trong nội bộ shot, nhiều hiệu ứng biên tập và thiếu dữ liệu chuyên biệt cho video ngắn.
4. **Dữ liệu nghiên cứu:** bộ dữ liệu SHOT được dùng làm tập trung tâm, đồng thời tham chiếu thêm các bộ dữ liệu BBC Planet Earth và ClipShots để đối chiếu.
5. **Phương pháp:** khảo sát TransNetV2 và AutoShot; phân tích cơ chế NAS; triển khai hướng cải tiến AutoShotV2 dựa trên tăng phân loại mới, Focal Loss, nhân many-hot, hiệu chỉnh nhiệt độ và làm mượt Gaussian.
6. **Thực nghiệm:** đánh giá bằng các chỉ số Precision, Recall, F1-score; so sánh mô hình cơ sở TransNetV2, AutoShot gốc và AutoShotV2 trên tập SHOT.
7. **Kết quả chính:** AutoShotV2 đạt $F1 = 0.8545$, cao hơn AutoShot gốc và vượt đáng kể so với mô hình cơ sở TransNetV2 trên tập kiểm tra SHOT.
8. **Kết cấu báo cáo:** gồm năm chương, lần lượt trình bày tổng quan, công trình liên quan, phương pháp, dữ liệu và thực nghiệm, kết luận và hướng phát triển.

Mục lục

LỜI CẢM ƠN	i
ĐỀ CƯƠNG CHI TIẾT	ii
MỤC LỤC	iii
DANH MỤC CHỮ VIẾT TẮT, THUẬT NGỮ CHUYÊN MÔN	vii
DANH MỤC CÁC HÌNH	xi
DANH MỤC CÁC BẢNG	xii
TÓM TẮT	xiii
1 TỔNG QUAN ĐỀ TÀI	1
1.1 Bối cảnh nghiên cứu	1
1.2 Phát biểu bài toán	2
1.3 Thách thức bài toán	4
1.4 Mục tiêu nghiên cứu	5
1.5 Phạm vi và giới hạn đề tài	6
1.6 Câu hỏi nghiên cứu	6
1.7 Hướng tiếp cận và đóng góp chính	7
1.7.1 Hướng tiếp cận	7
1.7.2 Đóng góp	8
1.8 Tổ chức khóa luận	8
1.9 Tổng kết chương	9
2 CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN	10
2.1 Tổng quan bài toán Shot Boundary Detection	10
2.2 Phương pháp cổ điển	11
2.2.1 Biểu đồ tần suất và chênh lệch điểm ảnh	11
2.2.2 Dựa trên biên cạnh và miền nén	12
2.2.3 Hạn chế của phương pháp cổ điển trên video ngắn	12

2.3	Phương pháp học sâu	13
2.3.1	DeepSBD và biến thể C3D	13
2.3.2	TransNet và TransNetV2	14
2.3.3	Tiếp cận Transformer và multi-modal	14
2.4	Neural Architecture Search trong thị giác máy tính và SBD	15
2.4.1	Tổng quan NAS	15
2.5	AutoShot và vị trí trong dòng nghiên cứu SBD	16
2.6	So sánh tổng quan các công trình liên quan	16
2.7	Vấn đề tồn tại và khoảng trống nghiên cứu	17
2.8	Tổng kết chương	19
3	PHƯƠNG PHÁP ĐỀ XUẤT	20
3.1	Tổng quan hướng tiếp cận	20
3.2	Kỹ thuật tìm kiếm kiến trúc mạng nơ-ron	20
3.2.1	Định nghĩa bài toán NAS	21
3.2.2	Không gian tìm kiếm	22
3.2.3	Chiến lược tìm kiếm	23
3.2.4	Chiến lược ước tính hiệu suất	24
3.3	Nền tảng: Mô hình TransNetV2	25
3.3.1	Tổng quan và vị trí trong dòng chảy nghiên cứu SBD	25
3.3.2	Kiến trúc mô hình	27
3.3.3	Hàm mục tiêu và quy trình huấn luyện	29
3.3.4	Thuật toán suy diễn với cửa sổ trượt	30
3.3.5	Thông số cấu hình	31
3.4	Mô hình AutoShot — nền tảng kế thừa từ TransNetV2	32
3.4.1	Động lực kế thừa từ TransNetV2	32
3.4.2	Không gian tìm kiếm kiến trúc	33
3.4.3	Quy trình tìm kiếm NAS	36
3.4.4	Huấn luyện lại và tinh chỉnh mô hình	40
3.4.5	Kiến trúc tối ưu của AutoShot	43
3.4.6	So sánh với TransNetV2	43
3.5	Biến thể AutoShotV2 — Cải tiến tầng phân loại và hậu xử lý	45
3.5.1	Động lực và chiến lược tổng thể	45
3.5.2	Kiến trúc ClassificationHead	46
3.5.3	Focal Loss – giải quyết mất cân bằng lớp	47
3.5.4	Nhãn many-hot — giám sát vùng biên	48

3.5.5	Gaussian Smoothing — triệt tiêu nhiễu đơn lẻ	49
3.5.6	Hiệu chỉnh nhiệt độ (Temperature Scaling) — hiệu chỉnh xác suất	50
3.5.7	Quy trình huấn luyện lại và thuật toán tổng thể	51
3.6	Tổng kết chương	51
4	BỘ DỮ LIỆU VÀ THỰC NGHIỆM	52
4.1	Bộ dữ liệu SHOT	52
4.1.1	Chi tiết bộ dữ liệu	52
4.1.2	Phân tích bộ dữ liệu	53
4.1.3	Tóm tắt bộ dữ liệu SHOT	55
4.2	Các bộ dữ liệu đánh giá bổ sung	56
4.2.1	Bộ dữ liệu BBC Planet Earth	56
4.2.2	Bộ dữ liệu ClipShots	56
4.2.3	So sánh tổng hợp các bộ dữ liệu	56
4.3	Các chỉ số đánh giá hiệu quả mô hình	57
4.4	Kịch bản thực nghiệm	58
4.5	Tổng quan các nhóm thực nghiệm	58
4.6	Kết quả chính trên ba bộ dữ liệu	59
4.7	So sánh Precision, Recall và F1-score	60
4.8	Kết quả tốt nhất theo từng bộ dữ liệu	60
4.9	Kết quả bổ sung theo biến thể	61
4.10	Kết quả kiểm định chéo theo từng bộ dữ liệu	62
4.11	Tổng kết chương	63
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	64
5.1	Thảo luận kết quả thực nghiệm	64
5.1.1	Breakdown theo bộ dữ liệu	64
5.1.2	Giải thích suy giảm trên ClipShots	64
5.1.3	Giới hạn của phân tích hiện tại	66
5.1.4	Phát hiện bổ sung ngoài phạm vi câu hỏi nghiên cứu	66
5.2	Kết luận chung	67
5.2.1	Trả lời các câu hỏi nghiên cứu	67
5.3	Đóng góp của khóa luận	68
5.4	Hạn chế của nghiên cứu	69
5.4.1	Chi phí tính toán của giai đoạn NAS	69

5.4.2	Nhạy cảm với chuyển động cực nhanh và hiệu ứng ánh sáng	70
5.4.3	Mất cân bằng dữ liệu chưa được giải quyết triệt để	70
5.4.4	Khoảng cách miền dữ liệu giữa SHOT và các bộ dữ liệu khác	70
5.5	Hướng phát triển tương lai	71
5.5.1	Tối ưu hóa real-time và triển khai trên thiết bị	71
5.5.2	Phát hiện đa phương thức (Multimodal SBD)	71
5.5.3	Khả năng tổng quát hóa xuyên miền	71
5.5.4	Phân loại fine-grained loại chuyển cảnh	72
5.5.5	Tự giám sát và mở rộng dữ liệu	72
5.5.6	Mở rộng dataset cho video tiếng Việt	72
5.6	Lời kết	72
Danh mục công trình của tác giả		74
Tài liệu tham khảo		75
A Ký hiệu toán học và quy ước đánh giá		79
A.1	Ký hiệu sử dụng trong khóa luận	80
A.2	Quy ước đánh giá	81
B Bảng tổng hợp kết quả bổ sung		82
B.1	Bộ dữ liệu SHOT	82
B.2	Bộ dữ liệu ClipShots	82
B.3	Bảng đầy đủ tất cả thực nghiệm	83

DANH MỤC CHỮ VIẾT TẮT, THUẬT NGỮ CHUYÊN MÔN

1. Chữ viết tắt

Ký hiệu	Cụm từ tiếng Anh	Giải thích
SBD	Shot Boundary Detection	Phát hiện ranh giới cảnh quay trong video.
SHOT	Short Video Shot Boundary Detection Dataset	Bộ dữ liệu chuyên biệt cho bài toán SBD trên video ngắn.
NAS	Neural Architecture Search	Kỹ thuật tự động tìm kiếm kiến trúc mạng nơ-ron tối ưu.
SPOS	Single-Path One-Shot	Chiến lược NAS một lần bắn với cơ chế lấy mẫu đường đi đơn.
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập dùng để học đặc trưng hình ảnh.
3D ConvNet	3D Convolutional Network	Mạng tích chập ba chiều khai thác đồng thời thông tin không gian và thời gian.
DDCNN	Dilated Deep Convolutional Neural Network	Khối tích chập giãn nở dùng trong TransNetV2 và AutoShot.
CT	Cut chuyển cảnh (<i>transition</i>)	Chuyển cảnh đột ngột giữa hai shot liên tiếp.
GT	chuyển cảnh dần (<i>gradual transition</i>)	Chuyển cảnh dần dần như <i>fade</i> , <i>dissolve</i> hoặc <i>wipe</i> .
TP	True Positive	Số chuyển cảnh được phát hiện đúng.
FP	dương tính giả (<i>false positive</i>)	Số báo động giả (mô hình báo có chuyển cảnh nhưng thực tế không có).
FN	False Negative	Số chuyển cảnh có thật nhưng bị bỏ sót.
BCE	Binary Cross-Entropy	Hàm mất mát nhị phân cho bài toán phân loại hai lớp.

Ký hiệu	Cụm từ tiếng Anh	Giải thích
FL	Focal Loss	Biến thể của BCE, giảm trọng số mẫu dễ phân loại để tập trung vào mẫu khó.
KD	chưng cất tri thức (<i>knowledge distillation</i>)	Chưng cất tri thức từ mô hình giáo viên sang mô hình học sinh.
EMA	Exponential Moving Average	Trung bình động mũ cho trọng số mô hình trong quá trình huấn luyện.
LS	Label Smoothing	Kỹ thuật làm mượt nhãn <i>one-hot</i> để giảm quá khớp (<i>overfitting</i>).
TS	Temperature Scaling	Hiệu chỉnh nhiệt độ để hiệu chuẩn (<i>calibrate</i>) phân phối xác suất đầu ra.
LR	Learning Rate	Tốc độ học của thuật toán tối ưu.
F1-score	Harmonic Mean of Precision and Recall	Chỉ số tổng hợp đánh giá cân bằng giữa Precision và Recall.

2. Thuật ngữ chuyên môn

Thuật ngữ	Giải thích ngắn gọn
Shot	Đơn vị cảnh quay liên tục giữa hai ranh giới thời gian kề nhau.
Scene	Tập hợp nhiều shot có cùng ngữ cảnh nội dung hoặc không gian thời gian.
Frame Similarity	Độ tương đồng giữa các khung hình lân cận, dùng để hỗ trợ phát hiện chuyển cảnh.
Color Histogram	Biểu diễn phân bố màu sắc của khung hình dưới dạng số liệu thống kê.
Factorized Convolution	Tách tích chập 3D thành các bước xử lý không gian và thời gian để giảm tham số.
Skip Connection	Kết nối tắt giữa các tầng mạng, giúp truyền thông tin ổn định hơn.

Thuật ngữ	Giải thích ngắn gọn
Focal Loss	Biến thể của BCE với nhân tử động $(1 - p_t)^\gamma$ làm giảm trọng số của các mẫu dễ phân loại; trong SBD, hai siêu tham số chính là γ (<i>focusing parameter</i>) và α (<i>balancing parameter</i>), thường được chọn qua grid search.
Many-hot Label	Kiểu nhãn mở rộng quanh vị trí ranh giới nhằm làm dày tín hiệu học.
Backbone	Mạng xương sống dùng để trích xuất đặc trưng cơ sở từ dữ liệu đầu vào.
Temporal modeling	Quá trình mô hình hóa các biến đổi theo thời gian giữa các khung hình.
Soft Label	Nhãn mềm mang giá trị xác suất (thay vì nhãn cứng 0 hoặc 1), thường dùng trong KD.
Knowledge Distillation	Kỹ thuật chuyển giao tri thức từ mô hình giáo viên sang mô hình học sinh, thường dùng nhãn mềm (<i>soft label</i>) để ổn định huấn luyện.
Temperature Scaling	Kỹ thuật hiệu chỉnh xác suất đầu ra sau huấn luyện: chia logit cho hệ số T^* duy nhất, được tìm bằng cách tối thiểu hóa NLL trên validation; giữ nguyên thứ tự xếp hạng dự đoán nên không ảnh hưởng F1 trước/sau ngưỡng hóa nếu ngưỡng cũng được chọn lại.
Gaussian Smoothing	Phép làm mượt chuỗi xác suất theo thời gian để giảm đỉnh nhiễu cô lập.
Threshold	Quá trình quét nhiều ngưỡng để chọn giá trị tối ưu cho Precision, Recall và F1.
SuperNet	Mạng lớn chứa nhiều kiến trúc con trong NAS, cho phép các kiến trúc chia sẻ trọng số khi đánh giá nhanh.
Bayesian Optimization	Phương pháp tối ưu hóa hộp đen dùng mô hình xác suất để chọn ứng viên kiến trúc tiếp theo.
Weight Grafting	Kỹ thuật ghép trọng số từ nhiều mô hình theo tiêu chí entropy nhằm tận dụng biểu diễn tốt ở từng lớp.
DARTS	Phương pháp NAS khả vi, biến lựa chọn kiến trúc rời rạc thành bài toán tối ưu liên tục.

Thuật ngữ	Giải thích ngắn gọn
Domain Adaptation	Nhóm kỹ thuật thích nghi miền giúp mô hình hoạt động ổn định hơn khi phân phối dữ liệu thay đổi.
Dropout	Kỹ thuật chính quy hóa bằng cách tắt ngẫu nhiên một phần đơn vị kích hoạt trong quá trình huấn luyện.
Baseline	Mô hình cơ sở dùng làm điểm chuẩn để so sánh hiệu năng.
Checkpoint	Điểm lưu trữ trạng thái trọng số của mô hình trong quá trình huấn luyện.
Weight Decay	Suy giảm trọng số, một kỹ thuật chính quy hóa giúp tránh quá khớp (<i>overfitting</i>) bằng cách phạt các trọng số lớn.
Ablation	Nghiên cứu phân rã/thử nghiệm loại trừ để đánh giá đóng góp của từng thành phần trong mô hình.
Grid Search	Tìm kiếm lưới, phương pháp quét qua một tập hợp các siêu tham số được định nghĩa trước để tìm cấu hình tối ưu.

Danh sách hình

1.1	Sự tăng trưởng và phổ biến của video ngắn trong những năm gần đây.	1
1.2	Phân cấp cấu trúc video: từ frames đến shots và scenes.	3
1.3	Các loại chuyển tiếp shot trong video.	3
1.4	Minh họa chuyển tiếp đột ngột (Cut chuyển cảnh).	3
1.5	Đặc thù video ngắn trên nền tảng TikTok.	4
1.6	Nhiều thị giác do ánh sáng thay đổi đột ngột (Flash).	5
2.1	Phổ các phương pháp học sâu được sử dụng trong phát hiện ranh giới cảnh quay.	11
3.1	Sơ đồ ba thành phần cốt lõi của NAS	21
3.2	Tổng quan kiến trúc TransNetV2	27
3.3	Cấu trúc khối DDCNN trong TransNetV2	28
3.4	Sơ đồ tổng thể mô hình AutoShot	34
3.5	Bốn biến thể khối tích chập 3D trong AutoShot	34
3.6	Sơ đồ 5 pha quy trình NAS trong AutoShot	36
3.7	Kiến trúc ClassificationHead trong AutoShotV2	46
3.8	Minh họa nhãn one-hot và many-hot	49
4.1	Minh họa các thách thức đặc thù trong SHOT	54
4.2	Phân bố độ dài video và shot trong SHOT	55
4.3	So sánh F1 trên tập SHOT	62

Danh sách bảng

2.1	So sánh tổng quan các nhóm phương pháp SBD	17
3.1	Đặc điểm của các loại không gian tìm kiếm NAS	22
3.2	So sánh các chiến lược tìm kiếm kiến trúc	24
3.3	So sánh các chiến lược ước tính hiệu suất trong NAS . . .	24
3.4	Các cải tiến chính từ TransNetV1 sang TransNetV2	26
3.5	Chiến lược dữ liệu huấn luyện của TransNetV2	30
3.6	Các thông số cấu hình của TransNetV2	31
3.7	Thành phần kế thừa từ TransNetV2 và đóng góp của công trình AutoShot gốc	33
3.8	So sánh bốn biến thể khối tích chập 3D phân tách của Au- toShot	35
3.9	Chi phí tính toán ước tính của từng pha trong AutoShot .	40
3.10	Kiến trúc tối ưu của AutoShot theo hai tiêu chí tối ưu . .	43
3.11	So sánh tổng hợp TransNetV2 và AutoShot	44
4.1	So sánh chi tiết các bộ dữ liệu đánh giá SBD	57
4.2	Tổng quan các nhóm thực nghiệm chính	58
4.3	So sánh F1-score các mô hình trên SHOT, BBC và ClipShots	59
4.4	Precision, Recall, F1 của AutoShotV2 trên ba bộ dữ liệu .	60
4.5	Đỉnh F1 theo từng bộ dữ liệu	61
4.6	Kết quả bổ sung theo biến thể mô hình	61
4.7	Kết quả bổ sung với EMA	62
4.8	F1 kiểm định chéo theo từng bộ dữ liệu	63
5.1	Breakdown theo loại chuyển cảnh trên ClipShots	65
B.1	Kết quả F1 trung bình trên tập kiểm tra của SHOT	82
B.2	Kết quả F1 trung bình trên ClipShots	83
B.3	Bảng đầy đủ tất cả thực nghiệm	84

TÓM TẮT

Video ngắn đang trở thành một dạng nội dung phổ biến, nhưng việc phân tích tự động loại video này vẫn gặp nhiều khó khăn vì nhịp dựng nhanh, cảnh quay thay đổi liên tục và hiệu ứng chuyển cảnh ngày càng đa dạng. Trong bối cảnh đó, phát hiện ranh giới cảnh quay là bước quan trọng để hệ thống có thể hiểu cấu trúc video trước khi thực hiện các tác vụ như tóm tắt, lập chỉ mục hoặc truy hồi nội dung.

Nghiên cứu này tập trung vào bài toán phát hiện ranh giới cảnh quay cho video ngắn. Trước hết, các hướng tiếp cận tiêu biểu được tổng hợp để làm rõ cách bài toán đã được xử lý từ các phương pháp dựa trên đặc trưng thủ công đến các mô hình học sâu. Từ nền tảng đó, mô hình AutoShot được chọn làm cơ sở để phân tích và cải tiến, với trọng tâm là điều chỉnh tầng phân loại và cách xử lý xác suất đầu ra nhằm giúp mô hình nhận biết ranh giới cảnh quay ổn định hơn.

Đóng góp chính của đề tài là đưa ra một hướng cải tiến phù hợp với đặc điểm của video ngắn mà không cần thay đổi toàn bộ kiến trúc mô hình ban đầu. Cách kết hợp một mạng xương sống đã được tối ưu với các điều chỉnh ở tầng phân loại cho thấy tiềm năng hỗ trợ tốt cho bài toán phát hiện ranh giới cảnh quay, đồng thời cũng đặt ra nhu cầu tiếp tục nâng cao khả năng tổng quát hóa khi áp dụng sang các miền dữ liệu khác. Những phân tích này có thể làm cơ sở cho các nghiên cứu tiếp theo về phân đoạn video và xây dựng dữ liệu video ngắn tiếng Việt.


Chương 1

TỔNG QUAN ĐỀ TÀI

Chương này trình bày bức tranh tổng thể của khóa luận: bối cảnh của bài toán phát hiện ranh giới cảnh quay (Shot Boundary Detection – SBD) cho video ngắn, phát biểu bài toán dưới dạng hình thức, các thách thức đặc thù, mục tiêu nghiên cứu, phạm vi giới hạn, ba câu hỏi nghiên cứu chính, đóng góp và cấu trúc tổ chức của báo cáo.

1.1 Bối cảnh nghiên cứu

Trong hơn một thập kỷ qua, video đã trở thành loại dữ liệu chiếm tỉ trọng lớn nhất trong lưu lượng Internet, được tiêu thụ rộng rãi trên các nền tảng như YouTube, Facebook và Instagram. Đáng chú ý hơn, sự bùng nổ của video ngắn trên TikTok, Kuaishou, YouTube Shorts và Instagram Reels trong những năm gần đây đã thay đổi căn bản cách người dùng tạo và tiêu thụ nội dung số. Cùng với hạ tầng mạng 5G, video ngắn và quảng cáo video tăng trưởng mạnh nhờ tính cô đọng, dễ chia sẻ và khả năng truyền tải thông tin hiệu quả hơn so với văn bản hay hình ảnh tĩnh.



Hình 1.1: Sự tăng trưởng và phổ biến của video ngắn trong những năm gần đây. Nguồn: VietnamNet Global (2023), dữ liệu theo Sprout Social [20].

Khối lượng dữ liệu khổng lồ này đặt ra thách thức trong việc quản lý,

tìm kiếm và tóm tắt nội dung video một cách thủ công. Nhu cầu về các hệ thống phân tích video tự động, chính xác về mặt thời gian vì thế trở nên cấp thiết. Phát hiện ranh giới cảnh quay là bước cơ bản và thiết yếu nhất của hầu hết quy trình phân tích video, đóng vai trò nền tảng cho các tác vụ phía sau như tóm tắt video, phân đoạn sự kiện và tạo video thông minh. Tuy đã có nhiều nghiên cứu trước đây, các phương pháp truyền thống chủ yếu hướng đến video dài (phim, tài liệu) và gặp khó khăn khi xử lý đặc thù động, phức tạp của video ngắn hiện đại. Vì vậy, việc xây dựng giải pháp SBD tối ưu cho video ngắn là một yêu cầu thực tế và cấp bách.


Theo hướng này, gần đây đã xuất hiện bộ dữ liệu chuyên biệt đầu tiên cho video ngắn [23] cùng các mô hình SBD học sâu được tối ưu cho miền dữ liệu mới. Tuy vậy, phần lớn mô hình cơ sở mạnh hiện hành vẫn được thiết kế cho video dài, mở ra dư địa cải thiện thông qua tìm kiếm kiến trúc mạng nơ-ron (NAS) và các kỹ thuật huấn luyện hiện đại — chi tiết khảo sát ở Chương 2. Mục tiêu cuối cùng là xây dựng một hệ thống SBD thích ứng tốt với sự năng động của video ngắn, đồng thời tận dụng các kiến trúc học sâu tiên tiến để giải quyết phần bài toán mà các phương pháp truyền thống còn bỏ ngỏ.

1.2 Phát biểu bài toán

Video được tổ chức theo cấu trúc phân cấp từ lớn đến nhỏ: *scene* (cảnh) chứa nhiều *shot* (cảnh quay), và mỗi shot là tập hợp các *frame* (khung hình) liên tiếp được ghi liên mạch. Phát hiện ranh giới cảnh quay là việc xác định các vị trí trong dòng khung hình nơi một shot kết thúc và một shot mới bắt đầu. Tác vụ này được thực hiện ở mức khung hình: nếu không có thay đổi đáng kể giữa các khung hình liên tiếp, không có ranh giới shot. Với chuyển cảnh dần, hệ thống thường phải quan sát đồng thời nhiều khung hình kế tiếp để xác nhận vì quá trình chuyển diễn ra trải dài theo thời gian.


Định nghĩa hình thức. Đầu vào của bài toán là một video $V = \{f_1, f_2, \dots, f_n\}$, trong đó f_i là khung hình thứ i . Đầu ra là tập các vị trí ranh giới $B = \{b_1, b_2, \dots, b_m\}$, với b_j là chỉ số khung hình bắt đầu một shot

mối.




Hình 1.2: Phân cấp cấu trúc video: từ frames đến shots và scenes.

Để phân biệt các shot, Khóa luận sử dụng cách phân loại chuyển tiếp được dùng phổ biến trong các nghiên cứu SBD [1], chia thành hai nhóm chính:



Hình 1.3: Các loại chuyển tiếp shot trong video.

- **Chuyển tiếp đột ngột – Cut chuyển cảnh (CT):** Là sự thay đổi tức thì giữa hai shot mà không có hiệu ứng chỉnh sửa nào ở giữa, xảy ra khi hai shot được nối trực tiếp. Đây là loại chuyển cảnh phổ biến và tương đối dễ phát hiện do sự thay đổi đột ngột về nội dung hình ảnh trong một khung hình.



Hình 1.4: Minh họa chuyển tiếp đột ngột (Cut chuyển cảnh).


- **Chuyển tiếp dần – chuyển cảnh dần (GT):** Là sự kết hợp giữa hai shot thông qua các hiệu ứng đồ họa, trải dài trên nhiều khung hình. Các dạng phổ biến: *Fade out* (shot mờ dần sang đen), *Fade in* (cảnh xuất hiện dần từ đen), *Dissolve* (hai shot chồng chéo), *Wipe* (shot mới đẩy shot cũ — khó phát hiện nhất do hình thức đa dạng). Xem Hình 1.3 để so sánh trực quan.

Bài toán đặt ra là xây dựng một mô hình học máy có khả năng tự động xác định chính xác vị trí thời gian của mọi ranh giới shot trong video.

1.3 Thách thức bài toán

Mặc dù SBD là bài toán đã được nghiên cứu lâu năm, việc áp dụng vào thực tế – đặc biệt với video ngắn – gặp nhiều thách thức đặc thù:

- **Đặc thù của video ngắn:** Video ngắn có nhịp độ rất nhanh, độ dài shot trung bình thường dưới 5 giây, ngắn hơn nhiều so với video truyền thống. Người sáng tạo nội dung thường kết hợp nhiều hiệu ứng chuyển cảnh phức tạp để tăng tính hấp dẫn. Ngoài ra, định dạng video dọc (vertical video) thường có các vùng tĩnh ở trên và dưới (như tên thương hiệu, tiêu đề), chỉ phần giữa thay đổi, gây khó khăn cho việc phát hiện thay đổi toàn cục.



Hình 1.5: Đặc thù video ngắn trên nền tảng TikTok.

- **Nội dung ảo và game:** Một tỷ lệ đáng kể video ngắn là video game với các cảnh ảo có sự thay đổi rất lớn trong nội bộ một shot do hiệu ứng kỹ xảo, dễ dẫn đến cảnh báo giả.
- **Nhiều thị giác:** Các yếu tố như thay đổi độ sáng đột ngột (đèn flash), chuyển động nhanh của vật thể hoặc camera (panning, zooming) và nền tương tự nhau giữa hai shot kế tiếp dễ bị nhầm lẫn với chuyển cảnh thật.



Hình 1.6: Nhiều thị giác do ánh sáng thay đổi đột ngột (Flash).

- **Khó khăn khi phát hiện chuyển cảnh dần:** Không giống Cut, GT diễn ra từ từ và có đặc điểm thống kê không rõ ràng. Các phương pháp dựa trên chênh lệch pixel hoặc histogram thường thất bại khi gặp các hiệu ứng dissolve hay wipe phức tạp.
- **Thiếu dữ liệu chuẩn cho video ngắn:** Các bộ dữ liệu truyền thống như BBC Planet Earth [2] chủ yếu chứa phim tài liệu hoặc tin tức với cảnh quay tương đối tĩnh, không phản ánh được độ phức tạp của video ngắn hiện đại.

Tóm lại, ba vấn đề cốt lõi của bài toán SBD cho video ngắn là: (i) ranh giới cảnh quay xuất hiện dày đặc nhưng không ổn định theo thời gian, (ii) tín hiệu nhiễu thị giác dễ bị nhầm thành chuyển cảnh thật, và (iii) khoảng cách miền dữ liệu giữa các bộ chuẩn truyền thống và dữ liệu video ngắn hiện đại. Đây là lý do cần một hướng tiếp cận vừa có năng lực biểu diễn đặc trưng mạnh, vừa đủ linh hoạt để thích nghi theo phân phối dữ liệu thực tế. Ba thách thức trên dẫn trực tiếp tới ba khoảng trống nghiên cứu sẽ được phân tích chi tiết ở Chương 2, làm cơ sở để đặt ba câu hỏi nghiên cứu RQ1–RQ3 ở mục dưới.

1.4 Mục tiêu nghiên cứu

Mục tiêu của khóa luận là cải thiện hiệu quả phát hiện ranh giới cảnh quay trên video ngắn dựa trên nền tảng AutoShot. Trọng tâm nghiên cứu

là giữ lại mạng xương sống đã được tối ưu bằng NAS, đồng thời khảo sát các cải tiến ở tầng phân loại và hậu xử lý xác suất để tăng khả năng nhận diện ranh giới trong bối cảnh dữ liệu có nhịp cắt nhanh, mất cân bằng lớp và nhiều hiệu ứng chuyển cảnh phức tạp.

1.5 Phạm vi và giới hạn đề tài

Trong khuôn khổ khóa luận này, bài toán được giới hạn theo các phạm vi sau:

- **Miền dữ liệu:** Tập trung xử lý video ở định dạng đã giải nén, tức là làm việc trực tiếp trên chuỗi khung hình thay vì dữ liệu nén.
- **Mục tiêu đầu ra:** Bài toán tập trung vào việc xác định vị trí biên thời gian (temporal boundary) của các shot; phân loại loại chuyển tiếp (Cut/Gradual) được nhận diện như ngữ cảnh phân tích nhưng không là mục tiêu thực nghiệm chính; chưa đi sâu vào việc hiểu ngữ nghĩa mức cao (như nhận diện hành động hay cảm xúc) bên trong shot.
- **Phương pháp luận:** Khóa luận tập trung vào việc ứng dụng và cải tiến các mô hình học sâu, cụ thể là mạng nơ-ron tích chập (CNN) và Transformer, thay vì các phương pháp dựa trên ngưỡng thủ công vốn có độ chính xác thấp hơn trên dữ liệu phức tạp.

1.6 Câu hỏi nghiên cứu

Để giải quyết các khoảng trống đã nêu, Khóa luận tập trung vào ba câu hỏi nghiên cứu chính:

- **RQ1:** Việc tối ưu kiến trúc theo hướng NAS có giúp cải thiện hiệu năng phát hiện ranh giới cảnh quay trên video ngắn so với mạng xương sống cố định như TransNetV2 hay không?
- **RQ2:** Các kỹ thuật huấn luyện và hậu xử lý ở tầng phân loại (Focal Loss, many-hot labels, temperature scaling, Gaussian smoothing) có thể cải thiện F1 mà không cần thay đổi mạng xương sống hay không?

- **RQ3:** Mức cải thiện đạt được trên SHOT có duy trì khi đánh giá chéo trên các bộ dữ liệu khác như BBC và ClipShots hay không?

1.7 Hướng tiếp cận và đóng góp chính

1.7.1 Hướng tiếp cận

Để giải quyết các thách thức nêu trên, Khóa luận tiếp cận bài toán dựa trên các kỹ thuật tiên tiến trong lĩnh vực thị giác máy tính:

- **Mạng nơ-ron tích chập 3D (3D ConvNets):** Sử dụng các kiến trúc 3D CNN để trích xuất đồng thời đặc trưng không gian và thời gian, giúp mô hình nắm bắt được sự vận động liên tục của video tốt hơn so với phương pháp 2D truyền thống.
- **Kiến trúc Transformer:** Tận dụng khả năng mô hình hóa phụ thuộc xa (long-range dependencies) của Transformer để xử lý các chuỗi khung hình dài, từ đó cải thiện khả năng phát hiện các chuyển cảnh dần kéo dài.
- **Tìm kiếm kiến trúc mạng nơ-ron (NAS):** Thay vì thiết kế thủ công, hướng tiếp cận này sử dụng NAS để tự động tối ưu thiết kế mô hình trong một không gian tìm kiếm chứa các khối 3D ConvNets và Transformer, nhằm đạt được cân bằng tốt giữa độ chính xác và chi phí tính toán.
- **Huấn luyện trên dữ liệu video ngắn chuyên biệt:** Sử dụng bộ dữ liệu SHOT [23] – bộ dữ liệu video ngắn quy mô lớn đầu tiên – để huấn luyện và đánh giá, qua đó đảm bảo mô hình thích nghi với các đặc trưng của video ngắn hiện đại.

Tổ hợp kế thừa AutoShot và cải tiến tăng phân loại này được ký hiệu là AutoShotV2 trong các chương sau.

Ánh xạ giữa câu hỏi nghiên cứu và hướng giải quyết:

- **RQ1** được kiểm chứng qua đối sánh TransNetV2 và AutoShot/AutoShotV2 trên cùng bộ tiêu chí đánh giá.

- **RQ2** được giải quyết bằng các cải tiến ở tầng phân loại và hậu xử lý xác suất, giữ nguyên mạng xương sống để tách biệt tác động của từng kỹ thuật.
- **RQ3** được đánh giá bằng thực nghiệm đa bộ dữ liệu (SHOT, BBC, ClipShots) nhằm kiểm tra mức độ tổng quát hóa.

1.7.2 Đóng góp

Trên cơ sở hướng tiếp cận đã nêu, Khóa luận mang lại các đóng góp chính sau:

- **Hệ thống hóa tri thức:** Trình bày có cấu trúc bối cảnh bài toán SBD cho video ngắn, từ phương pháp cổ điển đến học sâu và NAS, làm rõ khoảng trống nghiên cứu giữa dữ liệu truyền thống và dữ liệu video ngắn hiện đại.
- **Đóng góp về phương pháp:** Phân tích và triển khai quy trình AutoShot/AutoShotV2 [23, 16], trong đó bổ sung nhóm kỹ thuật cải tiến ở tầng phân loại và hậu xử lý (Focal Loss, nhãn many-hot, hiệu chỉnh nhiệt độ, làm mượt Gaussian) mà không thay đổi mạng xương sống.
- **Đóng góp về kết quả thực nghiệm:** Trên tập SHOT, AutoShotV2 đạt $F1 = 0.8545$ (+5.5 điểm phần trăm so với mô hình cơ sở TransNetV2); đồng thời cung cấp phân tích so sánh chéo trên BBC và ClipShots để đánh giá khả năng tổng quát hóa (chi tiết xem Chương 4).

1.8 Tổ chức khóa luận

Báo cáo được cấu trúc thành 5 chương:

- **Chương 1 – Tổng quan đề tài:** Giới thiệu bối cảnh, bài toán, thách thức, mục tiêu, phạm vi, câu hỏi nghiên cứu và đóng góp chính của khóa luận.

- **Chương 2 – Cơ sở lý thuyết và công trình liên quan:** Khảo sát các phương pháp SBD theo ba dòng chính – cổ điển dựa trên đặc trưng thủ công, học sâu với CNN/Transformer, và NAS – đồng thời nhận diện khoảng trống nghiên cứu.
- **Chương 3 – Phương pháp đề xuất:** Trình bày AutoShot như nền tảng kế thừa và phiên bản AutoShotV2 với các cải tiến ở tầng phân loại, hàm mất mát, nhân giám sát, hiệu chỉnh xác suất và làm mượt hậu xử lý.
- **Chương 4 – Bộ dữ liệu và thực nghiệm:** Mô tả các bộ dữ liệu (SHOT, BBC, ClipShots), chỉ số đánh giá, mô hình cơ sở, siêu tham số, kịch bản thực nghiệm, kết quả so sánh, phân tích Precision/Recall/F1 và thực nghiệm phân rã.
- **Chương 5 – Kết luận và hướng phát triển:** Thảo luận kết quả thực nghiệm, tổng kết kết quả chính, nhắc lại đóng góp, nêu hạn chế và đề xuất các hướng phát triển tiếp theo.

1.9 Tổng kết chương

Chương này đã giới thiệu bức tranh tổng quan về bài toán phát hiện ranh giới cảnh quay, nhấn mạnh tầm quan trọng của nó trong việc quản lý dữ liệu video lớn và đặc biệt là video ngắn. Các khái niệm cốt lõi về cấu trúc video, các loại chuyển cảnh Cut và Gradual, cùng các thách thức về đặc thù video ngắn, nội dung ảo, nhiễu thị giác và khoảng cách miền dữ liệu đã được phân tích. Khóa luận xác định hướng tiếp cận dựa trên học sâu và NAS, đặt ra ba câu hỏi nghiên cứu RQ1–RQ3, và cam kết ba nhóm đóng góp tương ứng. Đây là tiền đề để các chương tiếp theo đi sâu vào cơ sở lý thuyết và công trình liên quan, trình bày phương pháp đề xuất, thiết lập thực nghiệm, phân tích kết quả và tổng kết hướng phát triển.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN


Chương này trình bày nền tảng lý thuyết và các công trình liên quan cho bài toán phát hiện ranh giới cảnh quay (SBD), từ phương pháp cổ điển dựa trên đặc trưng thủ công, đến phương pháp học sâu hiện đại với CNN/3D ConvNet/Transformer, và gần đây nhất là hướng tìm kiếm kiến trúc mạng nơ-ron (NAS). Trên cơ sở đó, chương xác định các khoảng trống nghiên cứu làm nền cho phương pháp ở Chương 3, cũng như phần dữ liệu và thực nghiệm ở Chương 4.

2.1 Tổng quan bài toán Shot Boundary Detection

Các hướng nghiên cứu SBD có thể nhóm thành ba dòng chính, mỗi dòng có thể mạnh và giới hạn riêng (Hình 2.1):

- **Hướng cổ điển dựa trên đặc trưng thủ công.** Các phương pháp so sánh histogram màu, chênh lệch pixel hoặc biên cạnh có ưu điểm dễ triển khai và chi phí tính toán thấp. Tuy nhiên, chúng phụ thuộc mạnh vào ngưỡng thủ công, kém bền vững trước nhiễu ánh sáng/chuyển động và thường khó xử lý chuyển cảnh dần [1].
- **Hướng học sâu CNN/Transformer.** Các mô hình như DeepSBD [7] và TransNetV2 [16] học đặc trưng không-thời gian từ dữ liệu, cải thiện đáng kể Precision/Recall trên nhiều bộ chuẩn. Tuy vậy, kiến trúc mạng xương sống được thiết kế thủ công vẫn có nguy cơ chưa tối ưu cho video ngắn có nhịp cắt cảnh dày đặc.
- **Hướng NAS cho SBD.** Thay vì thiết kế thủ công, NAS [3, 14, 22] tự động tìm kiến trúc tốt nhất trong một không gian ứng viên. AutoShot [23] cho thấy hướng này có tiềm năng vượt các mô hình cơ

sở mạnh trên SHOT, nhưng hiệu quả tổng quát hóa sang các miền dữ liệu khác vẫn còn là câu hỏi mở.



Hình 2.1: Phổ các phương pháp học sâu được sử dụng trong phát hiện ranh giới cảnh quay.

Phần còn lại của chương đi sâu vào từng dòng phương pháp theo trình tự tiến hóa của lĩnh vực, kết thúc bằng bảng so sánh tổng quan và phân tích khoảng trống nghiên cứu.

2.2 Phương pháp cổ điển

Trước kỷ nguyên học sâu, các phương pháp SBD chủ yếu dựa trên đặc trưng thủ công và ngưỡng cố định. Khung xử lý điển hình của một thuật toán SBD cổ điển gồm ba bước: (i) trích xuất đặc trưng mức thấp từ mỗi khung hình, (ii) tính độ đo khoảng cách giữa các khung hình liên tiếp, và (iii) so ngưỡng để quyết định có ranh giới shot hay không [15, 1]. Nhóm phương pháp này có ưu điểm là đơn giản, dễ triển khai và chi phí tính toán thấp; tuy nhiên độ bền vững trước nhiễu cũng như khả năng tổng quát hóa trên dữ liệu đa dạng còn nhiều hạn chế [9].

2.2.1 Biểu đồ tần suất và chênh lệch điểm ảnh

Phương pháp Sum of Absolute Differences (SAD) [15, 1] so sánh chênh lệch pixel giữa hai khung hình liên tiếp: $D_{\text{pixel}} = \frac{1}{HW} \sum |f_{t-1}(x, y) - f_t(x, y)|$; đánh dấu ranh giới khi $D_{\text{pixel}} > \theta$. Histogram màu cải thiện bằng cách so sánh phân phối màu (χ^2 hoặc cosine distance), ít nhạy với chuyển động nhỏ hơn SAD. Cả hai phù hợp với chuyển cảnh đột ngột

nhưng kém hiệu quả với chuyển cảnh dần và dễ bị nhiễu bởi thay đổi ánh sáng [1].

2.2.2 Dựa trên biên cạnh và miền nén

Một nhánh cổ điển khác sử dụng đặc trưng biên cạnh để đo sự thay đổi cấu trúc giữa các khung hình. Tỷ lệ *Edge Change Ratio* (ECR) đếm tỷ lệ pixel biên xuất hiện hoặc biến mất khi đi từ f_{t-1} sang f_t , qua đó nắm bắt được các chuyển cảnh dạng fade và dissolve tốt hơn so với histogram thuần túy.

Để giảm chi phí giải nén toàn bộ video, các phương pháp *compressed-domain* khai thác trực tiếp dữ liệu trong dòng bit nén (ví dụ vector chuyển động và DCT coefficient của chuẩn MPEG) [9]. Cách tiếp cận tương tự là dùng *optical flow* để ước lượng chuyển động giữa hai khung hình: nếu trường vector flow thay đổi đột ngột về phân bố, khả năng cao đó là một ranh giới shot. Các phương pháp này tiết kiệm chi phí tính toán nhưng độ chính xác phụ thuộc mạnh vào chất lượng tín hiệu chuyển động được nén và thường yêu cầu tinh chỉnh ngưỡng theo từng bộ mã hóa-giải mã.

2.2.3 Hạn chế của phương pháp cổ điển trên video ngắn

Khi áp dụng vào video ngắn, các phương pháp cổ điển bộc lộ ba hạn chế cốt lõi:

1. **Độ phụ thuộc ngưỡng cao:** Mỗi tập dữ liệu hoặc thậm chí từng video cần một ngưỡng riêng để cân bằng Precision–Recall. Trong video ngắn với nhịp cắt dày và phong cách hậu kỳ đa dạng, một ngưỡng cố định khó đạt hiệu quả tổng quát.
2. **Kém bền vững với nhiễu thị giác:** Đèn flash, chuyển động máy quay nhanh và hiệu ứng kỹ xảo trong nội bộ shot dễ tạo ra các đỉnh giả trong tín hiệu khoảng cách, dẫn đến cảnh báo giả.
3. **Yếu với chuyển cảnh dần phức tạp:** Các hiệu ứng dissolve, wipe và morph có gradient thay đổi mượt theo thời gian, khiến độ đo dựa trên khác biệt liên kề không tạo ra đỉnh đủ rõ để vượt ngưỡng.

Những hạn chế này đặt nền tảng cho việc chuyển sang hướng học đặc trưng từ dữ liệu, được trình bày trong mục tiếp theo.

2.3 Phương pháp học sâu

Sự phát triển của mạng nơ-ron tích chập (CNN), mạng tích chập 3D (3D ConvNet) và đặc biệt là kiến trúc Transformer đã giúp SBD chuyển từ đặc trưng thủ công sang đặc trưng học được. Cách tiếp cận này tăng đáng kể độ chính xác và khả năng mô hình hóa ngữ cảnh không-thời gian. Mục này lần lượt khảo sát các mô hình tiêu biểu theo trình tự lịch sử phát triển.

2.3.1 DeepSBD và biến thể C3D

DeepSBD do Hassanien và cộng sự đề xuất [7] là một trong những mô hình SBD học sâu đầu tiên cho kết quả thuyết phục trên quy mô lớn. Mạng sử dụng kiến trúc C3D [19] để trích xuất đặc trưng không-thời gian từ một clip ngắn gồm 16 khung hình liên tiếp. Đầu ra của C3D được đưa qua một bộ phân loại đa lớp để dự đoán đồng thời ba khả năng: *không có chuyển cảnh*, *cut*, hoặc *gradual*.

Điểm mạnh của DeepSBD nằm ở khả năng học đặc trưng không-thời gian đầu-cuối, qua đó tránh được nhược điểm của ngưỡng thủ công ở phương pháp cổ điển. Kết quả trên các bộ dữ liệu lớn cho thấy DeepSBD vượt trội đáng kể so với các mô hình cơ sở cổ điển trên chuyển cảnh khó và dữ liệu đa miền. Tuy nhiên, kiến trúc dựa trên C3D có hai hạn chế:

- Số lượng tham số lớn (khoảng 78 triệu theo cấu hình gốc [19]) khiến chi phí huấn luyện cao và dễ quá khớp trên các tập dữ liệu vừa và nhỏ.
- Cửa sổ thời gian cố định 16 khung hình hạn chế khả năng nắm bắt các chuyển cảnh dần kéo dài, vốn phổ biến trong video ngắn.

2.3.2 TransNet và TransNetV2

TransNet [17] và TransNetV2 [16] là các mô hình cơ sở mạnh trong SBD hiện đại. TransNetV2 khai thác các khối tích chập giãn cho phép tăng trường tiếp nhận thời gian mà không tăng số tham số tương ứng. Cùng với kỹ thuật *kernel factorization* tách 3D convolution thành chuỗi $2D + 1D$ convolution, TransNetV2 đạt mức cân bằng tốt giữa độ chính xác và chi phí tính toán.

Hai cải tiến đáng chú ý của TransNetV2 so với TransNet là:

- **Nhánh đặc trưng tương đồng (frame similarity branch):** Tính ma trận tương đồng giữa các khung hình trong cùng cửa sổ, cung cấp tín hiệu phụ trợ giúp mô hình phân biệt chuyển cảnh thật với nhiễu chuyển động.
- **Hai đầu phân loại song song:** Một đầu dự đoán xác suất chuyển cảnh đơn-khung (single-frame chuyển cảnh), một đầu dự đoán xác suất "thuộc về một chuyển cảnh dần" (all-frames-of-chuyển cảnh). Hai tín hiệu này được kết hợp ở giai đoạn suy diễn để vừa định vị chính xác vị trí cut, vừa bao quát được toàn bộ vùng gradual.

Tuy là mô hình cơ sở mạnh, TransNetV2 chủ yếu được tối ưu trên các bộ dữ liệu video dài (phim, tài liệu) như BBC Planet Earth. Khi áp dụng sang video ngắn có shot dày đặc, hiệu ứng chuyển cảnh phức tạp và nhiều nhiễu thị giác, kiến trúc mạng xương sống cố định bộc lộ giới hạn về tổng quát hóa. Chi tiết kiến trúc và hàm mục tiêu của TransNetV2 được trình bày đầy đủ trong Chương 3 (Phần A) vì TransNetV2 đóng vai trò mô hình cơ sở trực tiếp của khóa luận.

2.3.3 Tiếp cận Transformer và multi-modal

Sau thành công của Transformer [21] trong xử lý chuỗi, nhiều nghiên cứu SBD gần đây áp dụng cơ chế self-attention để mô hình hóa phụ thuộc xa giữa các khung hình. Esteve và cộng sự [4] đề xuất một mô hình kết hợp 3D depthwise convolution với visual attention, cho thấy attention có thể hỗ trợ tốt cho convolution trong việc phát hiện các chuyển cảnh dần

dài. Theo cùng hướng, nhiều công trình khảo sát trong các tổng kết gần đây [9] cho thấy xu hướng dùng kết hợp đa phương thức (kết hợp đặc trưng hình ảnh với âm thanh hoặc tín hiệu chuyển động) để tăng tính bền vững khi chuyển miền dữ liệu.

Mặc dù vậy, các phương pháp dựa trên Transformer thường có chi phí tính toán cao do độ phức tạp bậc hai theo độ dài chuỗi, và việc thiết kế thủ công không gian ứng viên cho từng đặc thù dữ liệu vẫn là vấn đề mở. Đây chính là động cơ dẫn đến hướng tiếp cận tiếp theo: để máy tự tìm kiến trúc thay vì thiết kế thủ công.

2.4 Neural Architecture Search trong thị giác máy tính và SBD

2.4.1 Tổng quan NAS

Neural Architecture Search (NAS) là kỹ thuật tự động hóa quá trình thiết kế kiến trúc mạng nơ-ron. Một bài toán NAS được đặc trưng bởi ba thành phần chính [3]:

- **Không gian tìm kiếm ($\mathcal{A}$):** tập hợp tất cả các kiến trúc khả dĩ. Có thể là toàn bộ mạng (macro search), một khối lặp lại (cell-based) hoặc tổ hợp phân cấp (hierarchical).
- **Chiến lược tìm kiếm:** cách thuật toán duyệt không gian $\mathcal{A}$. Các họ phương pháp tiêu biểu gồm học tăng cường (RL), giải thuật tiến hóa (EA), và phương pháp khả vi (DARTS [11]).
- **Chiến lược ước tính hiệu suất:** cách đánh giá nhanh một kiến trúc ứng viên mà không cần huấn luyện từ đầu. Kỹ thuật nổi bật là *one-shot NAS* với cơ chế chia sẻ trọng số trong một *SuperNet* duy nhất [6].

Trong ba thành phần trên, chiến lược ước tính hiệu suất là yếu tố quyết định tính khả thi tính toán của NAS. Phương pháp *Single-Path One-Shot* (SPOS) [6] huấn luyện một SuperNet chứa mọi đường đi ứng viên với cơ chế lấy mẫu đồng đều, sau đó các kiến trúc con kế thừa trọng số từ SuperNet

và chỉ cần đánh giá trực tiếp trên tập kiểm định mà không cần huấn luyện lại. Cách tiếp cận này giảm chi phí NAS từ hàng nghìn GPU-day xuống còn vài chục GPU-hour, mở đường cho NAS thực tế trong các bài toán thị giác máy tính cụ thể như SBD.

2.5 AutoShot và vị trí trong dòng nghiên cứu SBD

AutoShot [23] là công trình tiêu biểu đưa NAS vào bài toán SBD, đặc biệt hướng đến video ngắn. Đóng góp của AutoShot gồm hai phần:

- **Bộ dữ liệu SHOT:** Bộ dữ liệu video ngắn quy mô lớn đầu tiên dành cho SBD, gồm 853 video với 11,606 chú thích ranh giới shot, kèm cơ chế làm mờ khuôn mặt để bảo vệ quyền riêng tư.
- **Mô hình AutoShot:** Sử dụng SuperNet một lần bắn theo phong cách SPOS [6] trên không gian tìm kiếm gồm bốn biến thể khối tích chập giãn (DDCNNV2, A, B, C). Tổng kích thước không gian tìm kiếm vào khoảng 83.9 triệu kiến trúc ứng viên. Quá trình tìm kiếm sử dụng Bayesian Optimization, kèm hai kỹ thuật huấn luyện lại là *Knowledge Distillation* [8] và *Weight Grafting* theo entropy.

Trên tập SHOT, AutoShot cho thấy ưu thế rõ rệt so với mô hình cơ sở TransNetV2, xác nhận tiềm năng của hướng NAS trong môi trường shot ngắn và chuyển cảnh phức tạp. Tuy nhiên, AutoShot tập trung tối ưu phần mạng xương sống mà chưa khảo sát sâu các kỹ thuật ở tầng phân loại và hậu xử lý (Focal Loss, nhãn many-hot, hiệu chỉnh nhiệt độ, làm mượt Gaussian). Đây chính là khoảng trống mà phiên bản cải tiến *AutoShotV2* của khóa luận hướng đến lấp đầy, được trình bày trong Phần B của Chương 3.

2.6 So sánh tổng quan các công trình liên quan

Bảng 2.1 tổng hợp các nhóm phương pháp tiêu biểu theo hướng tiếp cận, loại mô hình, bộ dữ liệu thường được sử dụng, ưu điểm và hạn chế. Mục tiêu của bảng là đặt các công trình liên quan vào cùng một bức tranh

phương pháp luận; các kết quả định lượng chi tiết được trình bày riêng ở Chương 4.

Bảng 2.1: So sánh tổng quan các nhóm phương pháp SBD theo hướng tiếp cận, loại mô hình, bộ dữ liệu thường dùng, ưu điểm và hạn chế.

Nhóm phương pháp	Loại mô hình	Bộ dữ liệu (Dataset) thường dùng	Ưu điểm	Hạn chế
Đặc trưng thủ công	Histogram, pixel difference, edge-based, compressed-domain	BBC và các tập video truyền thống	Đơn giản, dễ triển khai, chi phí thấp	Phụ thuộc ngưỡng, dễ nhiễu bởi ánh sáng/chuyển động, yếu với chuyển cảnh dần phức tạp
Đặc trưng học sâu [7]	3D ConvNet/C3D	Tập dữ liệu SBD quy mô lớn	Học đặc trưng không-thời gian đầu-cuối, giảm phụ thuộc đặc trưng thủ công	Nhiều tham số, chi phí huấn luyện cao, cửa sổ thời gian cố định
TransNet/-TransNetV2 [17, 16]	CNN 3D giản nở, frame similarity, hai đầu phân loại	BBC, ClipShots	Mô hình cơ sở mạnh, cân bằng tốt giữa độ chính xác và tốc độ	Mạng xương sống thiết kế thủ công, chưa tối ưu riêng cho video ngắn có nhịp cắt dày
AutoShot [23]	NAS trên mạng xương sống SBD	SHOT, ClipShots và các tập đánh giá bổ sung	Tự động tìm kiếm trúc phù hợp hơn với video ngắn, kế thừa quy trình mạnh từ TransNetV2	Chi phí NAS cao, còn ít phân tích về tầng phân loại và hậu xử lý xác suất
AutoShotV2	Mạng xương sống AutoShot + cải tiến tầng phân loại	SHOT, BBC, ClipShots	Tập trung cải thiện tầng phân loại và hậu xử lý mà không thay đổi toàn bộ mạng xương sống	Cần kiểm tra thêm khả năng tổng quát hóa đa miền và các biến thể chuyển cảnh phức tạp

2.7 Vấn đề tồn tại và khoảng trống nghiên cứu

Từ khảo sát ở các mục 2.2–2.4 và bảng so sánh tổng quan 2.1, Khóa luận xác định ba khoảng trống nghiên cứu chính làm cơ sở cho phương pháp đề xuất:

- **Khoảng trống 1 – Sai khác miền dữ liệu giữa video dài truyền**

thông và video ngắn hiện đại. Hầu hết các kiến trúc mạnh hiện nay (đặc biệt TransNetV2) được tối ưu trên dữ liệu video dài như BBC Planet Earth, vốn có nhịp cắt cảnh thưa và ít hiệu ứng kỹ xảo. Khi chuyển sang video ngắn – nơi shot trung bình ngắn dưới 5 giây và xuất hiện dày đặc các hiệu ứng dissolve/wipe – các kiến trúc này không còn tối ưu. NAS là một hướng tiềm năng để giải quyết, nhưng chi phí tính toán của NAS vẫn là rào cản với nhiều đơn vị nghiên cứu vừa và nhỏ.

- **Khoảng trống 2 – Tổng quát hóa đa miền chưa được giải quyết trọn vẹn.** Mô hình tối ưu cho một miền dữ liệu có thể suy giảm khi chuyển sang các miền khác như ClipShots hoặc BBC. Hiện tượng dịch chuyển miền dữ liệu trong SBD chưa có giải pháp tổng quát: các nghiên cứu hiện hành thường báo cáo kết quả tốt nhất trên một bộ dữ liệu mục tiêu mà chưa phân tích hệ thống mức suy giảm chéo. Điều này tạo nhu cầu cho các thực nghiệm đánh giá chéo có hệ thống, như được tiến hành trong Chương 4 của khóa luận.
- **Khoảng trống 3 – Thiếu phân tích hệ thống về hiệu chỉnh xác suất và hậu xử lý.** Phần lớn các công trình SBD tập trung cải tiến mạng xương sống (DeepSBD, TransNetV2, AutoShot) trong khi ít phân tích hệ thống về các kỹ thuật ở tầng đầu ra: hàm mất mát cho dữ liệu mất cân bằng (Focal Loss [10]), giám sát theo ranh giới với nhãn many-hot, hiệu chỉnh nhiệt độ (temperature scaling [5]) để cải thiện độ tin cậy (calibration) của xác suất dự đoán, và làm mượt Gaussian để giảm phổ tần số cao trong dòng xác suất đầu ra. Đây là khoảng trống mà khóa luận trực tiếp đề xuất giải pháp thông qua AutoShotV2.

Ba khoảng trống này tương ứng trực tiếp với RQ1, RQ3 và RQ2 ở Mục 1.6: NAS cho video ngắn, tổng quát hóa đa miền, và hiệu chỉnh tầng đầu ra. Đây là động lực cốt lõi để Chương 3 của khóa luận triển khai phương pháp đề xuất theo hướng: giữ nền tảng kiến trúc mạng xương sống mạnh từ AutoShot, đồng thời tăng cường khả năng thích nghi với video ngắn và tổng quát hóa đa miền thông qua thiết kế lại tầng phân loại và quy trình

huấn luyện–hậu xử lý.

2.8 Tổng kết chương

Chương này đã trình bày bức tranh công trình liên quan từ phương pháp cổ điển đến học sâu hiện đại và NAS, kèm theo công thức hình thức cho các độ đo cổ điển và phân tích đặc trưng kiến trúc của các mô hình học sâu tiêu biểu (DeepSBD, TransNetV2, AutoShot, các biến thể Transformer/multi-modal). Bảng so sánh tổng quan cho thấy mỗi hướng tiếp cận có ưu điểm và giới hạn riêng, đặc biệt là khoảng cách giữa dữ liệu video dài truyền thống và video ngắn hiện đại. Từ các quan sát trên, ba khoảng trống nghiên cứu đã được xác định rõ – sai khác miền dữ liệu, tổng quát hóa đa miền và hiệu chỉnh xác suất đầu ra – là nền tảng trực tiếp cho Chương 3, nơi khóa luận đi sâu vào nền tảng kế thừa và phương pháp đề xuất.

Chương 3

PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày phương pháp được sử dụng trong khóa luận. Trọng tâm là kế thừa AutoShot, giữ lại mạng xương sống đã được NAS tối ưu, sau đó cải tiến tầng phân loại, hàm mất mát, nhãn giám sát và các bước hậu xử lý xác suất để hình thành AutoShotV2. Các phần nền tảng về NAS và TransNetV2 được giữ lại ở mức cần thiết nhằm làm rõ cơ sở kế thừa trước khi đi vào phương pháp cải tiến; dữ liệu, thiết lập thực nghiệm và kết quả định lượng được trình bày ở Chương 4.

3.1 Tổng quan hướng tiếp cận


Khóa luận tiếp cận bài toán theo hướng kế thừa một mạng xương sống SBD đã được tối ưu bằng Neural Architecture Search, sau đó tập trung cải thiện các thành phần ở tầng đầu ra. Cụ thể, AutoShot được dùng làm mô hình nền tảng; phần mạng xương sống được giữ nguyên để bảo toàn lợi ích của quá trình tìm kiếm kiến trúc, còn AutoShotV2 bổ sung ClassificationHead mới, Focal Loss, nhãn many-hot, temperature scaling và Gaussian smoothing nhằm xử lý mất cân bằng lớp, tăng tín hiệu giám sát quanh ranh giới và ổn định chuỗi xác suất dự đoán theo thời gian. Hai mục tiếp theo hệ thống hóa hai khối kiến thức nền tảng được khóa luận kế thừa: (i) các nguyên lý và kỹ thuật của Neural Architecture Search (Mục 3.2) – là công cụ trung tâm mà AutoShot vận dụng để tìm ra kiến trúc tối ưu cho SBD, và (ii) mô hình TransNetV2 (Mục 3.3) – là mô hình cơ sở trực tiếp để khóa luận so sánh và cải tiến.

3.2 Kỹ thuật tìm kiếm kiến trúc mạng nơ-ron

Tìm kiếm kiến trúc mạng nơ-ron (Neural Architecture Search — NAS) là quá trình tự động hóa việc thiết kế kiến trúc mạng nơ-ron nhằm đạt hiệu suất cao trên một nhiệm vụ cụ thể mà không cần can thiệp thủ công

từ chuyên gia [22]. NAS được xem là bước tiến tự nhiên của học máy tự động (Automated Machine Learning — AutoML), mở rộng phạm vi tối ưu hóa từ siêu tham số sang toàn bộ cấu trúc mô hình. Trong thập kỷ qua, các kiến trúc được tìm kiếm tự động liên tục thiết lập kết quả tốt nhất trên nhiều bộ chuẩn đánh giá, đáng chú ý nhất là bộ dữ liệu ImageNet. Lĩnh vực này phát triển nhanh chóng với hơn 1000 bài báo được công bố chỉ trong hai năm tính đến 2022 [22], phản ánh tầm quan trọng của tự động hóa thiết kế mô hình trong học sâu hiện đại.

Theo khảo sát toàn diện của Elsken et al. [3] và Ren et al. [14], hầu hết các phương pháp NAS đều được tổ chức quanh ba thành phần cốt lõi liên kết chặt chẽ với nhau: *không gian tìm kiếm* xác định phạm vi các kiến trúc có thể xét đến, *chiến lược tìm kiếm* quyết định cách duyệt qua không gian đó một cách hiệu quả, và *chiến lược ước tính hiệu suất* giúp đánh giá nhanh chất lượng từng ứng viên mà không phải huấn luyện đầy đủ từ đầu. Ba thành phần này tạo thành một vòng lặp phản hồi: thiết kế không gian tìm kiếm ảnh hưởng trực tiếp đến chiến lược tìm kiếm phù hợp, còn phương pháp ước tính hiệu suất quyết định tốc độ toàn bộ vòng lặp NAS. Hình 3.1 minh họa sơ đồ tổng quan của ba thành phần này.



Hình 3.1: Sơ đồ ba thành phần cốt lõi của NAS: không gian tìm kiếm (không gian tìm kiếm), chiến lược tìm kiếm (search strategy) và chiến lược ước tính hiệu suất (performance estimation strategy) liên kết nhau thành vòng lặp phản hồi. Đầu ra là kiến trúc tối ưu a^* đáp ứng ngân sách tính toán t .

3.2.1 Định nghĩa bài toán NAS

NAS tìm kiến trúc a^* tối ưu hóa độ chính xác trên tập xác thực trong ngân sách tính toán t :

$$a^* = \arg \max_{a \in \mathcal{A}} \text{val_acc}(a), \quad \text{trong ngân sách } t. \quad (3.1)$$

Thách thức: không gian $\mathcal{A}$ rời rạc, không khả vi, có thể hàng triệu cấu hình — huấn luyện đầy đủ từng kiến trúc không khả thi. Trong SBD, kiến trúc tối ưu phụ thuộc mạnh vào đặc điểm dữ liệu (nhịp cắt, loại chuyển cảnh), nên NAS đặc biệt có giá trị để tìm mạng xương sống chuyên biệt cho từng phân phối dữ liệu — đây là luận điểm trung tâm của AutoShot.

3.2.2 Không gian tìm kiếm

Không gian tìm kiếm $\mathcal{A}$ xác định tập hợp tất cả các kiến trúc mạng nơ-ron khả thi. Thiết kế không gian tìm kiếm là quyết định quan trọng nhất trong NAS vì nó định hình toàn bộ quá trình: không gian quá lớn dẫn đến chi phí tìm kiếm khổng lồ và khó hội tụ, trong khi không gian quá hẹp có thể loại bỏ các kiến trúc tiềm năng. Thực tế, phần lớn các kiến trúc tìm kiếm tốt đều được thiết kế không gian tìm kiếm lấy cảm hứng mạnh từ các kiến trúc thủ công tiên tiến [22].

Ba dạng không gian tìm kiếm phổ biến: (i) **Macro** — tìm kiếm toàn bộ mạng, tự do tối đa nhưng chi phí rất cao; (ii) **Hierarchical** — xây dựng kiến trúc theo nhiều cấp lồng nhau, cân bằng giữa linh hoạt và chi phí; (iii) **Cell-based** — tìm một đơn vị cấu trúc nhỏ (cell/block) rồi xếp chồng, phổ biến nhất hiện nay (NASNet, DARTS). AutoShot theo triết lý cell-based: không gian tìm kiếm định nghĩa ở cấp block (DDCNNV2/A/B/C), toàn mạng là tổ hợp 6 block độc lập. Bảng 3.1 tổng hợp đặc điểm của ba loại.

Bảng 3.1: Đặc điểm của các loại không gian tìm kiếm NAS

Loại không gian	Kích thước	Linh hoạt	Chi phí tìm kiếm
Vĩ mô (Macro)	Rất lớn	Rất cao	Rất cao
Phân cấp (Hierarchical)	Lớn	Cao	Cao
Dựa trên tế bào (Cell-based)	Trung bình	Trung bình	Trung bình
AutoShot	83.9M kiến trúc	Cao (4 loại block)	Trung bình (SuperNet)

3.2.3 Chiến lược tìm kiếm

Chiến lược tìm kiếm khám phá không gian $\mathcal{A}$ cân bằng giữa *khám phá* vùng chưa biết và *khai thác* vùng đã biết tốt [22].

Kỹ thuật tối ưu hóa hộp đen

Các kỹ thuật hộp đen huấn luyện từng kiến trúc độc lập và không yêu cầu gradient, phù hợp với không gian rời rạc. Ba hướng chính: *RL* [3] mô hình hóa tìm kiếm như bài toán quyết định tuần tự với RNN làm controller, nhận F1 validation làm phần thưởng — chi phí cao (hàng trăm đến hàng nghìn GPU-giờ); *EA* [3] tiến hóa quần thể kiến trúc qua đột biến và lai ghép — dễ song song hóa nhưng vẫn tốn đánh giá; *Tối ưu hóa Bayesian (BO)* [3] xây dựng Gaussian Process xấp xỉ hàm hiệu suất và dùng hàm thu thập để chọn ứng viên tiếp theo một cách thông minh, hiệu quả mẫu nhất trong nhóm. AutoShot sử dụng BO với GP và hàm PoF ở giai đoạn tìm kiếm (Mục 3.4.3).

Kỹ thuật một lần bắn và DARTS

Các phương pháp một lần bắn (One-Shot) mã hóa toàn bộ không gian tìm kiếm vào một *supernetwork* duy nhất, cho phép tất cả kiến trúc con chia sẻ trọng số và được đánh giá nhanh mà không cần huấn luyện riêng. **DARTS** [14] là biến thể phổ biến nhất, chuyển không gian rời rạc thành dạng liên tục qua softmax có trọng số trên các phép toán ứng viên; tuy giảm chi phí xuống vài GPU-giờ nhưng gặp vấn đề *khoảng cách rời rạc hóa* khi argmax cuối cùng phá vỡ biểu diễn liên tục đã học — điểm yếu chí mạng với không gian rời rạc như các biến thể DDCNN.

AutoShot vì vậy chọn *Single-Path One-Shot* (SPOS): tại mỗi bước huấn luyện, một kiến trúc con được lấy mẫu đồng đều và chỉ trọng số của đường đi đó được cập nhật. Cách làm này tránh tương quan giữa các nhánh và hoạt động ổn định với không gian hoàn toàn rời rạc; sau khi SuperNet hội tụ, mọi kiến trúc con có thể được đánh giá tức thời bằng cách kế thừa trọng số chia sẻ.

Bảng 3.2 tóm tắt đặc điểm và đánh đổi của các chiến lược tìm kiếm

chính, giúp định vị AutoShot trong toàn cảnh NAS.

Bảng 3.2: So sánh các chiến lược tìm kiếm kiến trúc

Chiến lược	Chi phí GPU	Yêu cầu gradient	Không gian rời rạc	Ví dụ
Học tăng cường (RL)	Rất cao	Không	Có	NASNet
Tiến hóa (EA)	Cao	Không	Có	AmoebaNet
Tối ưu hóa Bayesian (BO)	Trung bình	Không	Có	AutoShot
DARTS (One-Shot)	Thấp	Có	Không	PC-DARTS
Single-Path One-Shot	Thấp	Không	Có	SPOS, AutoShot

3.2.4 Chiến lược ước tính hiệu suất

Ước tính hiệu suất thay thế huấn luyện đầy đủ (vài giờ GPU/kiến trúc) bằng xấp xỉ nhanh: (i) *Lower-fidelity* rút ngắn huấn luyện hoặc dùng tập con dữ liệu; (ii) *Zero-cost proxy* chỉ cần một lần lan truyền để gán điểm cho kiến trúc; (iii) *Weight sharing* (chiến lược AutoShot) — SuperNet chia sẻ trọng số cho tất cả kiến trúc con, cho phép đánh giá bất kỳ kiến trúc trong vài giây. Bảng 3.3 tóm tắt đánh đổi chi phí–độ chính xác.

Bảng 3.3: So sánh các chiến lược ước tính hiệu suất trong NAS

Chiến lược	Chi phí đánh giá	Độ chính xác xếp hạng	Ví dụ ứng dụng
Huấn luyện đầy đủ	Rất cao	Cao nhất	NASNet (RL)
Lower-fidelity	Trung bình	Trung bình	Hyperband-NAS
Zero-cost proxy	Gần bằng 0	Thấp–Trung bình	NASWOT, GradNorm
Weight sharing (one-shot)	Thấp	Trung bình–Cao	SPOS, AutoShot

Trong AutoShot: không gian tìm kiếm = 83.9M kiến trúc (phương trình (3.4)), chiến lược = SPOS + BO (Mục 3.4.3), ước tính hiệu suất = weight sharing từ SuperNet.

Điểm khởi đầu của AutoShot là TransNetV2 — một kiến trúc được thiết kế thủ công chuyên biệt cho SBD. AutoShot giữ nguyên các thành phần cốt lõi (DDCNN, similarity branch, two-head, sliding window) nhưng đa dạng hóa cách kết hợp tích chập không gian–thời gian thành bốn biến thể, tạo không gian tìm kiếm phong phú hơn. Sau đó, NAS tự động tìm cấu hình tối ưu thay vì chuyên gia quyết định thủ công. Phần tiếp theo sẽ phân tích nền tảng TransNetV2 trước khi trình bày những đóng góp đặc trưng của AutoShot.

3.3 Nền tảng: Mô hình TransNetV2

TransNetV2 là mô hình mạng nơ-ron sâu được Souček và Lokoč đề xuất năm 2020 [16], với mục tiêu phát hiện ranh giới cảnh quay trong video một cách nhanh chóng và chính xác. Mô hình kế thừa TransNet (2019) và mang lại nhiều cải tiến căn bản về kiến trúc và quy trình huấn luyện. Mã nguồn và trọng số huấn luyện sẵn được tác giả công bố rộng rãi, tạo nền tảng quan trọng cho cộng đồng nghiên cứu và là điểm khởi đầu trực tiếp của AutoShot.

3.3.1 Tổng quan và vị trí trong dòng chảy nghiên cứu SBD

Trước TransNetV2, phần lớn các phương pháp SBD dùng đặc trưng thủ công (histogram màu, pixel difference) hoặc mạng CNN xử lý từng cặp khung hình riêng lẻ. Nhóm phương pháp đầu dễ cài đặt nhưng thiếu khả năng nắm bắt ngữ cảnh thị giác phức tạp; nhóm sau học được đặc trưng phong phú hơn nhưng không mô hình hóa ngữ cảnh thời gian dài hạn — quan trọng để phân biệt chuyển cảnh đột ngột (thay đổi đột ngột) với chuyển cảnh dần (thay đổi dần dần như dissolve, fade).

TransNetV2 giải quyết cả hai hạn chế này đồng thời: khối tích chập giãn nở 3D (DDCNN) học đặc trưng thời gian đa tỉ lệ trực tiếp từ dữ liệu thô, trong khi nhánh đặc trưng tương đồng cung cấp tín hiệu bổ sung về sự thay đổi nội dung giữa các khung hình. Tích chập phân tách không gian–thời gian (tích chập phân tách) giảm số tham số xuống còn khoảng 6.5 triệu trong khi vẫn duy trì trường nhìn thời gian rộng lên tới 97 khung

hình.

So với TransNetV1, TransNetV2 cải thiện F1-score đáng kể trên các bộ dữ liệu chuẩn: từ 73.5% lên 77.9% trên ClipShots và từ 92.9% lên 96.2% trên BBC Planet Earth. Những cải thiện này đến từ sự kết hợp đồng bộ của bốn thay đổi quan trọng, được tổng hợp trong Bảng 3.4.


Bảng 3.4: Các cải tiến chính từ TransNetV1 sang TransNetV2

Thành phần	TransNetV1	TransNetV2
Chuẩn hóa	Không có	BatchNorm sau mỗi tích chập
Kết nối	Tuần tự	Skip connection sau mỗi 2 khối
Kernel tích chập	3D đầy đủ	Phân tách không gian-thời gian
Nhánh bổ sung	Không có	Learned + Histogram similarity
Đầu ra	Một head	Hai heads (single + all frame)
Dữ liệu huấn luyện	Nhân tạo 100%	Nhân tạo 85% + Thực 15%
F1 ClipShots	73.5%	77.9%
F1 BBC Planet Earth	92.9%	96.2%

Mỗi thay đổi trong Bảng 3.4 giải quyết một vấn đề cụ thể. BatchNorm và skip connection ổn định quá trình huấn luyện khi mô hình sâu hơn. Phân tách kernel giảm nguy cơ quá khớp trên dữ liệu nhân tạo có phân phối hạn chế. Nhánh similarity cung cấp tín hiệu bổ sung không thể học được chỉ từ tích chập cục bộ. Hai heads buộc mô hình phân biệt giữa "tại đâu là ranh giới" và "vùng nào là chuyển cảnh", hai câu hỏi bổ sung cho nhau. Cuối cùng, bổ sung dữ liệu thực vào 15% tập huấn luyện thu hẹp khoảng cách phân phối giữa huấn luyện và kiểm thử.

3.3.2 Kiến trúc mô hình

TransNetV2 xử lý chuỗi khung hình đầu vào có kích thước $48 \times 27 \times 3$ pixel với độ dài 100 khung, trả ra xác suất ranh giới cho mỗi khung hình. Kiến trúc gồm hai nhánh song song — nhánh DDCNN chính và nhánh đặc trưng tương đồng — được kết hợp trước các đầu phân loại, như minh họa trong Hình 3.2.




Hình 3.2: Tổng quan kiến trúc TransNetV2: 6 khối DDCNN giãn nở xếp chồng (nhánh chính) kết hợp với nhánh đặc trưng tương đồng (histogram RGB + learned similarity), đầu ra qua hai đầu phân loại song song (single-frame head và all-frame head). Kết nối tắt và pooling trung bình không gian được áp dụng sau mỗi hai khối DDCNN.

Khối tích chập giãn nở DDCNN

Xương sống của TransNetV2 là 6 khối tích chập giãn nở (Dilated DCNN — DDCNN) xếp chồng tuần tự. Mỗi khối DDCNN gồm 4 nhánh tích chập song song với độ giãn nở (dilation) theo chiều thời gian tăng dần theo cấp số nhân: $d \in \{1, 2, 4, 8\}$. Đầu ra của 4 nhánh được nối ghép (concatenate) theo chiều kênh, tiếp theo là BatchNorm và ReLU. Sau mỗi hai khối DDCNN, một skip connection và lớp pooling trung bình không gian được thêm vào để ổn định luồng gradient và giảm dần độ phân giải không gian.

Hình 3.3 minh họa cấu trúc chi tiết của một khối DDCNN với 4 nhánh dilation song song.



Hình 3.3: Cấu trúc chi tiết của khối DDCNN trong TransNetV2: 4 nhánh tích chập thời gian 1D với độ giãn nở $d \in \{1, 2, 4, 8\}$ song song nhau, đầu ra được nối ghép theo chiều kênh. Mỗi nhánh trước tiên qua tích chập không gian 2D ($1 \times k \times k$) rồi mới qua tích chập thời gian 1D giãn nở ($k \times 1 \times 1$).

Nhờ cấu trúc giãn nở, trường nhìn thời gian (temporal receptive field) tại khối DDCNN thứ k có thể được tính theo quy nạp. Với kernel thời gian kích thước $K = 3$ và 4 nhánh dilation $\{1, 2, 4, 8\}$, trường nhìn cộng dồn sau k khối là:

$$R_k = R_{k-1} + 2 \cdot (K - 1) \cdot \sum_{d \in \{1, 2, 4, 8\}} d = R_{k-1} + 2 \cdot 2 \cdot 15 = R_{k-1} + 60, \quad (3.2)$$

với $R_0 = 1$ (một khung hình đơn lẻ). Cơ chế cộng dồn cho $R_1 = 61$, $R_2 = 121$, $\dots$, $R_6 = 361$ trong trường hợp lý tưởng. Tuy nhiên, chiều dài chuỗi đầu vào trong huấn luyện và suy diễn được cố định ở mức 100 khung hình, nên trường nhìn bị cắt cụt; kết hợp với các lớp pooling xen kẽ, trường nhìn hiệu quả (effective receptive field) tập trung vào khoảng 97 khung hình — đủ bao quát toàn bộ chuỗi đầu vào, giúp mô hình nắm bắt ngữ cảnh dài hạn để phân biệt cảnh tan dần (dissolve) với chuyển động chậm (slow motion).

Phân tách tích chập không gian–thời gian

Thay vì dùng kernel tích chập 3D đầy đủ kích thước $k \times k \times k$, TransNetV2 phân tách mỗi phép tích chập thành hai bước tuần tự nhằm giảm số tham số và buộc mạng học riêng biệt hai loại thông tin:

1. **Tích chập không gian 2D** với kernel $1 \times k \times k$: xử lý từng khung hình trong chuỗi một cách độc lập theo hai chiều không gian (height, width), học đặc trưng nội dung thị giác như cạnh, kết cấu, vùng màu.

2. **Tích chập thời gian 1D giản nở** với kernel $k \times 1 \times 1$ và độ giãn nở d : xử lý chuỗi đặc trưng theo trục thời gian, học sự biến đổi chuyển động và chuyển cảnh.

Phân tách giảm số tham số còn $\approx 44\%$ so với kernel 3D đầy đủ: với $k = 3$ và $C_{in} = C_{out} = C_{mid} = C$, tỉ lệ là $(9C^2 + 3C^2)/(27C^2) = 12/27 \approx 44\%$, tức tiết kiệm $\approx 56\%$ tham số bất kể số kênh. Ngoài lợi ích về bộ nhớ, việc ép xử lý không gian trước rồi mới xử lý thời gian tạo ra thiên kiến quy nạp phù hợp với SBD: nội dung khung thay đổi theo không gian, còn chuyển cảnh là hiện tượng theo thời gian — hai biến đổi nên được mô hình hóa riêng biệt.

Nhánh đặc trưng tương đồng và hai đầu phân loại

Song song với DDCNN, TransNetV2 tính ma trận tương đồng qua hai nguồn bổ sung: *learned similarity* (cosine similarity giữa đặc trưng ℓ_2 -chuẩn hóa trích từ L_2, L_4, L_6) và *histogram RGB similarity* (cosine distance của histogram 512-bin). Hai loại tương đồng (mỗi loại 101 chiều) được ghép thành 202-D, qua Dense(128)+ReLU rồi kết hợp với đầu ra DDCNN. Learned similarity nhạy với thay đổi ngữ nghĩa; histogram nhạy với thay đổi màu sắc thô — sự kết hợp tăng tính bền vững qua nhiều loại chuyển cảnh.

Hai đầu phân loại: *Single-frame head* dự đoán xác suất tại đúng một khung trung tâm của ranh giới (đầu ra chính khi suy diễn); *All-frame head* dự đoán xác suất "thuộc về vùng chuyển cảnh" (hỗ trợ học phạm vi chuyển cảnh dần). Cơ chế hai đầu là cải tiến then chốt so với TransNetV1.

3.3.3 Hàm mục tiêu và quy trình huấn luyện

Hàm mất mát weighted cross-entropy

TransNetV2 tối thiểu hóa weighted cross-entropy tổng hợp hai nhánh kèm ℓ_2 :

$$\mathcal{L}(\theta) = \frac{\lambda_1}{KM} \sum_{i,t} \text{CE}(\hat{y}_{i,t}^{(1)}, y_{i,t}^{(1)}) + \frac{\lambda_2}{KM} \sum_{i,t} \text{CE}(\hat{y}_{i,t}^{(2)}, y_{i,t}^{(2)}) + \lambda_{\text{reg}} \|\theta\|^2, \quad (3.3)$$

với $\lambda_1 = 5.0$, $\lambda_2 = 0.1$, $\lambda_{\text{reg}} = 10^{-4}$. Trọng số $\lambda_1 \gg \lambda_2$ ưu tiên nhánh single-frame vốn mất cân bằng lớp nghiêm trọng hơn.

Chiến lược dữ liệu và tăng cường

Tập huấn luyện kết hợp 85% dữ liệu nhân tạo (chuyển cảnh đột ngột và dissolve tạo từ IACC.3 + ClipShots) và 15% dữ liệu thực (ClipShots). Tăng cường dữ liệu được áp dụng *nhất quán cho toàn chuỗi* (flip, màu sắc, color transfer 10%) để tránh artifact thời gian giả tạo. Chuyển đổi màu giả lập trường hợp khó: hai cảnh liên kề có tông màu tương đồng, buộc mô hình học đặc trưng cấu trúc thay vì chỉ dựa vào màu sắc (Bảng 3.5).

Bảng 3.5: Chiến lược dữ liệu huấn luyện của TransNetV2

Loại mẫu	Nguồn / Cách tạo	Tỉ lệ
Chuỗi thực	ClipShots (ranh giới cảnh thực)	15%
chuyển cảnh đột ngột nhân tạo	IACC.3 + ClipShots, nối 2 cảnh	35%
Dissolve nhân tạo	IACC.3 + ClipShots, hiệu ứng hòa tan	50%
Tăng cường	Flip, màu sắc, color transfer (10%)	100%

3.3.4 Thuật toán suy diễn với cửa sổ trượt

Thuật toán 1 mô tả cơ chế cửa sổ trượt xử lý video có độ dài tùy ý. TransNetV2 chỉ nhận đầu vào có độ dài cố định 100 khung, nên cần chia video dài thành các đoạn chồng lấp. Mỗi cửa sổ 100 khung di chuyển với bước nhảy 50 khung; chỉ 50 khung hình ở giữa (vị trí 25–74) được giữ lại trong kết quả, tránh hiệu ứng biên ở hai đầu cửa sổ nơi ngữ cảnh thời gian bị thiếu.

Thuật toán 1 TransNetV2 Inference

```
1: function PREDICT(video,  $\theta^*$ ,  $\tau = 0.5$ )
2:   frames  $\leftarrow$  ExtractFrames(video)
3:   frames  $\leftarrow$  Resize(frames,  $48 \times 27 \times 3$ )
4:   predictions  $\leftarrow$  []
5:   for start = 0 to  $|frames| - 100$  step 50 do
6:      $\hat{y}^{(1)} \leftarrow$  Forward( $\theta^*$ , frames[start : start + 100])
7:     predictions.extend( $\hat{y}^{(1)}$ [25 : 75])  $\triangleright$  Keep middle 50 frames
8:   positions  $\leftarrow$  {t : predictions[t] >  $\tau$ }
9:   boundaries  $\leftarrow$  GroupConsecutive(positions)  $\triangleright$  Gradual: multiple
    consecutive frames
10:  return boundaries
```

Quy trình suy diễn này được AutoShot tái sử dụng nguyên vẹn: chỉ 50 khung giữa được giữ lại, đảm bảo video được bao phủ đầy đủ và tránh sai số ở biên cửa sổ.

3.3.5 Thông số cấu hình

Bảng 3.6 tổng hợp các siêu tham số chính, phục vụ đối chiếu với AutoShot ở Mục 3.4.6. Mô hình ≈ 6.5 M tham số, huấn luyện ≈ 17 giờ trên V100.

Bảng 3.6: Các thông số cấu hình của TransNetV2

Tham số	Giá trị
Độ phân giải đầu vào	$48 \times 27 \times 3$
Độ dài chuỗi huấn luyện	100 khung hình
Bước trượt suy diễn	50 khung hình
Kích thước batch	16
Tốc độ học	0.01
Momentum (SGD)	0.9
Số epoch huấn luyện	50
Trọng số loss (λ_1, λ_2)	5.0, 0.1
Chính quy hóa (λ_{reg})	10^{-4}
Trường nhìn thời gian hiệu quả	≈ 97 khung hình
Tổng số tham số	≈ 6.5 triệu
Bộ nhớ GPU (batch 16)	≈ 2 GB
Thời gian huấn luyện (V100)	≈ 17 giờ

Từ nền tảng NAS và TransNetV2 đã trình bày, các mục tiếp theo cụ thể hóa khung NAS thành hai mô hình. Trước hết, Mục 3.4 mô tả AutoShot — một instance của khung NAS với 83.9 triệu kiến trúc ứng viên, dùng SuperNet kết hợp Bayesian Optimization để chọn mạng xương sống phù hợp với phân phối video ngắn của SHOT. Tiếp theo, Mục 3.5 trình bày đóng góp của khóa luận: biến thể AutoShotV2 đóng băng mạng xương sống đã được NAS tối ưu, chỉ huấn luyện lại tầng phân loại với Focal Loss, nhân many-hot, Gaussian smoothing và temperature scaling — nhằm cô lập đóng góp của tầng đầu ra so với mạng xương sống.

3.4 Mô hình AutoShot — nền tảng kế thừa từ TransNetV2

3.4.1 Động lực kế thừa từ TransNetV2

AutoShot [23] bắt đầu từ một nhận xét thực nghiệm: TransNetV2 [16] là mô hình cơ sở mạnh cho SBD, nhưng chỉ đạt $F1 = 79.9\%$ trên SHOT, thấp hơn kỳ vọng khi chuyển sang miền video ngắn. Vấn đề không nằm ở toàn bộ quy trình TransNetV2, vì các quyết định như cửa sổ trượt, nhánh similarity và hai đầu phân loại vẫn phù hợp. Điểm cần tối ưu là **backbone**: TransNetV2 dùng cùng một dạng DDCNN cho 6 vị trí, trong khi video ngắn có nhịp cắt nhanh, hiệu ứng chỉnh màu dày đặc và phân phối chuyển cảnh khác video dài.

Vì vậy, AutoShot không thay thế TransNetV2 từ đầu. Mô hình giữ lại quy trình đã được kiểm chứng, rồi dùng Neural Architecture Search (NAS) để chọn cấu hình mạng xương sống phù hợp hơn với SHOT và ClipShots. Cách tổ chức này giúp so sánh công bằng: nếu hiệu năng tăng, nguyên nhân chính đến từ cơ chế chọn kiến trúc bằng NAS chứ không phải từ việc đổi toàn bộ quy trình suy diễn hay hàm mục tiêu.

Hai luận điểm kỹ thuật được kiểm chứng trong AutoShot:

- **H1**: mạng xương sống cố định với 6 khối DDCNN đồng nhất chưa tối ưu cho video ngắn; chuyên biệt hóa theo từng vị trí có thể cải thiện F1.

- **H2:** NAS one-shot trên không gian gồm các biến thể DDCNN và tùy chọn Transformer có thể tìm kiến trúc vượt TransNetV2 với chi phí huấn luyện chấp nhận được.


Bảng 3.7 phân rõ thành phần nào của AutoShot được kế thừa từ TransNetV2 và thành phần nào là đóng góp của công trình AutoShot gốc.

Bảng 3.7: Thành phần kế thừa từ TransNetV2 và đóng góp của công trình AutoShot gốc

Thành phần	Kế thừa / Mới	Mô tả
Độ phân giải đầu vào (48×27)	Kế thừa	Giữ nguyên
Nhánh similarity (learned + hist.)	Kế thừa	Giữ nguyên
Hai đầu phân loại (single + all)	Kế thừa	Giữ nguyên
Hàm mất mát (WCE hai nhánh)	Kế thừa	Giữ nguyên
Suy diễn sliding window	Kế thừa	Giữ nguyên
Loại khối mạng xương sống	Mới	4 biến thể DDCNNV2/A/B/C
Khối Transformer (vị trí 7)	Mới	Tùy chọn self-attention
Quy trình NAS (SuperNet + BO)	Mới	Tìm kiếm kiến trúc tự động
chưng cất tri thức	Mới	Học từ nhãn mềm
Weight Grafting	Mới	Kết hợp trọng số theo entropy

3.4.2 Không gian tìm kiếm kiến trúc


Không gian tìm kiếm của AutoShot được thiết kế hẹp có chủ đích: chỉ thay đổi các khối trích xuất đặc trưng trong mạng xương sống, còn phần vào/ra và quy trình suy diễn vẫn giữ theo TransNetV2. Cụ thể, mô hình có 7 quyết định kiến trúc nối tiếp: 6 vị trí đầu chọn khối tích chập phân tách 3D, vị trí cuối chọn số lớp Transformer 1D. Hình 3.4 minh họa sơ đồ tổng thể, trong đó mỗi biến α_i là một quyết định rời rạc của NAS.



Hình 3.4: Sơ đồ tổng thể mô hình AutoShot gồm 7 vị trí kiến trúc cần tìm kiếm. Sáu vị trí đầu là các khối tích chập phân tách 3D chọn từ $\mathcal{V} = \{\text{DDCNNV2}, \text{DDCNNV2A}, \text{DDCNNV2B}, \text{DDCNNV2C}\}$ với các siêu tham số (nc, nd) ; vị trí thứ 7 là khối Transformer 1D với số lớp tự chú ý $\alpha_7 \in \{0, 1, 2, 3, 4\}$. Nhánh similarity và hai đầu phân loại được kế thừa nguyên vẹn từ TransNetV2, do đó mọi cải thiện đo được đều quy về sự khác biệt ở 7 quyết định $\alpha_1, \dots, \alpha_7$ của NAS.

Bốn biến thể khối tích chập

Hình 3.5 minh họa bốn biến thể khối tích chập 3D phân tách trong không gian tìm kiếm. Tất cả đều kế thừa nguyên tắc tích chập phân tách từ TransNetV2 (Mục 3.3.2), nhưng khác nhau ở cách chia sẻ spatial convolution và cách ghép đặc trưng spatial-temporal. Bảng 3.8 tóm tắt vai trò của từng biến thể.



Hình 3.5: Bốn biến thể khối tích chập 3D phân tách trong không gian tìm kiếm của AutoShot. Từ trái qua phải: DDCNNV2 (spatial riêng biệt từng nhánh, concat), DDCNNV2A (shared spatial, concat), DDCNNV2B (spatial + temporal song song, cộng dồn theo P3D), DDCNNV2C (spatial truyền tuần tự vào temporal, cộng dồn). Tất cả đều dùng tích chập thời gian 1D giãn nở đa nhánh.

Bảng 3.8: So sánh bốn biến thể khối tích chập 3D phân tách của AutoShot

Biến thể	Spatial conv	Phép kết hợp	Nguồn cảm hứng
DDCNNV2	Riêng biệt từng nhánh	Concat	TransNetV2 gốc
DDCNNV2A	Dùng chung (shared)	Concat	Chia sẻ đặc trưng không gian
DDCNNV2B	Song song với temporal	Add	Pseudo-3D (P3D)
DDCNNV2C	Tuần tự vào temporal	Add	Kết hợp DDCNNV2A + B

Bảng 3.8 là nguồn so sánh chính giữa bốn biến thể; điểm cốt lõi cần ghi nhớ là không gian tìm kiếm phủ hai trục thiết kế: *cách chia sẻ spatial convolution* (riêng biệt như V2 vs. dùng chung như V2A, V2C) và *cách ghép spatial-temporal* (Concat như V2/V2A vs. Add lấy cảm hứng P3D như V2B/V2C). Đưa cả hai cơ chế Concat và Add vào không gian tìm kiếm cho phép NAS tự cân nhắc giữa tính phân tách thông tin (Concat) và sự ổn định gradient kiểu ResNet (Add) phù hợp nhất với từng vị trí trong mạng xương sống của video ngắn.

Kích thước không gian tìm kiếm

Với 4 loại khối và các tùy chọn siêu tham số như mô tả trong Bảng 3.8, số cấu hình khả thi cho mỗi khối tích chập là:

- DDCNNV2: $3 \times 2 = 6$ cấu hình (3 giá trị nc , 2 giá trị nd)
- DDCNNV2A: $3 \times 2 = 6$ cấu hình
- DDCNNV2B: $1 \times 2 = 2$ cấu hình (nc cố định, 2 giá trị nd)
- DDCNNV2C: $1 \times 2 = 2$ cấu hình
- Tổng mỗi khối tích chập: $6 + 6 + 2 + 2 = 16$ cấu hình

Khối Transformer thứ 7 có 5 tùy chọn về số lớp self-attention: $\{0, 1, 2, 3, 4\}$. Các 6 khối tích chập được cấu hình độc lập, nên tổng số

kiến trúc trong không gian tìm kiếm là:


$$|\mathcal{A}| = 16^6 \times 5 = 16,777,216 \times 5 = 83,886,080 \approx 83.9 \text{ triệu kiến trúc.} \quad (3.4)$$

Không gian gần 84 triệu kiến trúc này quá lớn để duyệt toàn bộ bằng phương pháp naïve (đánh giá từng kiến trúc độc lập sẽ cần hàng nghìn năm GPU). Đây là lý do cốt lõi tại sao AutoShot cần quy trình NAS hai giai đoạn với SuperNet và Bayesian Optimization, được trình bày tiếp theo.

3.4.3 Quy trình tìm kiếm NAS

Áp dụng khung NAS đã trình bày ở Mục 3.2, AutoShot cụ thể hóa ba thành phần không gian tìm kiếm, search strategy và performance estimation thành quy trình hai lớp dưới đây.

AutoShot áp dụng One-Shot NAS kết hợp Tối ưu hóa Bayesian. Có thể nhìn quy trình ở hai lớp: **lớp tìm kiếm** gồm huấn luyện SuperNet và chọn kiến trúc bằng BO; **lớp hoàn thiện mô hình** gồm retraining, chưng cất tri thức và Weight Grafting. Hình 3.6 tóm tắt toàn bộ luồng 5 pha từ thiết kế không gian tìm kiếm đến mô hình cuối cùng.



Đầu ra: mô hình AutoShot tối ưu cho bài toán SBD video ngắn

Hình 3.6: Sơ đồ 5 pha của quy trình NAS trong AutoShot: (1) Thiết kế không gian tìm kiếm với 83.9M kiến trúc; (2) Huấn luyện SuperNet theo chiến lược Single-Path One-Shot; (3) Tìm kiếm kiến trúc tối ưu bằng Bayesian Optimization (GP + PoF); (4) Huấn luyện lại kiến trúc α^* ; (5) Tinh chỉnh bằng chưng cất tri thức và Weight Grafting.

Giai đoạn 1: Huấn luyện SuperNet (Single-Path One-Shot)

SuperNet là một mạng duy nhất triển khai tất cả 83.9 triệu kiến trúc trong không gian tìm kiếm thông qua cơ chế chia sẻ trọng số (weight sharing). Mỗi trong 6 vị trí khối tích chập, SuperNet duy trì đầy đủ trọng số cho tất cả 16 cấu hình khả thi; tại mỗi bước huấn luyện, chỉ một đường đi (path) được kích hoạt và cập nhật.

Chiến lược *Single-Path One-Shot* hoạt động như sau: tại mỗi bước huấn luyện, lấy mẫu ngẫu nhiên một vector cấu hình $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_6, \alpha_7] \in \mathcal{A}$

theo phân phối đồng đều, trong đó α_i xác định loại và siêu tham số của khối thứ i . Chỉ trọng số của các lớp tương ứng với α được kích hoạt trong bước forward/backward, còn phần còn lại không được cập nhật. Về mặt toán học, cập nhật tham số tại bước n là:

$$\theta_{\text{super}}[\alpha^{(n)}] \leftarrow \theta_{\text{super}}[\alpha^{(n)}] - lr \cdot \nabla_{\theta[\alpha^{(n)}]} \mathcal{L}(\alpha^{(n)}, \mathcal{B}^{(n)}), \quad (3.5)$$

trong đó $\alpha^{(n)}$ là kiến trúc được lấy mẫu tại bước n , $\mathcal{B}^{(n)}$ là batch dữ liệu, và $\mathcal{L}$ là hàm mất mát giống phương trình (3.3).

Chiến lược lấy mẫu đồng đều đảm bảo mọi kiến trúc con được huấn luyện với xác suất bằng nhau, tránh thiên lệch về một loại khối nhất định. Điều này quan trọng để trọng số chia sẻ θ_{super} phản ánh khả năng chung của tất cả kiến trúc, không bị áp đảo bởi một số ít kiến trúc chiếm ưu thế. Sau khi huấn luyện 12 epoch, θ_{super} đóng vai trò oracle đánh giá nhanh: cho bất kỳ kiến trúc α , điểm F1 ước tính được tính bằng cách nạp θ_{super} và suy diễn trên tập xác thực mà không cần huấn luyện lại.

Thuật toán 2 mô tả quy trình huấn luyện SuperNet; điểm mới so với TransNetV2 là bước lấy mẫu kiến trúc α ở đầu mỗi vòng lặp (iteration) và chỉ cập nhật có chọn lọc theo α .

Dù trọng số chia sẻ (shared) không tối ưu cho bất kỳ kiến trúc con cụ thể nào, *thứ tự xếp hạng* giữa các kiến trúc con khi dùng trọng số chia sẻ tương quan cao với thứ tự khi huấn luyện độc lập [14], đủ để BO hướng dẫn tìm kiếm. Sau 12 epoch, hàm đánh giá nhanh chỉ cần nạp θ_{super} vào α và suy diễn trên tập xác thực (Thuật toán 1), mất vài giây thay vì nhiều giờ.

Thuật toán 2 SuperNet Training (Single-Path One-Shot)

```
1: function TRAINSUPERNET( $\mathcal{S}$ ,  $epochs = 12$ )
2:   Initialize  $\theta_{\text{super}}$  randomly
3:   Set:  $lr = 0.1$ ,  $momentum = 0.9$ ,  $batch\_size = 16$ ,  $\lambda_1 = 5.0$ ,
    $\lambda_2 = 0.1$ 
4:   for  $epoch = 1 \dots epochs$  do
5:     for  $iter = 1 \dots num\_iterations$  do
6:        $\alpha \leftarrow \text{SampleUniform}(\mathcal{S})$   $\triangleright$  Sample sub-architecture
       uniformly at random
7:        $\mathcal{B} \leftarrow \text{CreateBatch}(\text{SHOT} \cup \text{ClipShots}, batch\_size)$ 
8:        $(\hat{y}^{(1)}, \hat{y}^{(2)}) \leftarrow \text{Forward}(\theta_{\text{super}}, \mathcal{B}, \alpha)$ 
9:        $\mathcal{L} \leftarrow \lambda_1 \cdot \text{CE}(y^{(1)}, \hat{y}^{(1)}) + \lambda_2 \cdot \text{CE}(y^{(2)}, \hat{y}^{(2)})$ 
10:       $\theta_{\text{super}}[\alpha] \leftarrow \theta_{\text{super}}[\alpha] - lr \cdot \nabla_{\theta_{\text{super}}[\alpha]} \mathcal{L}$   $\triangleright$  Update only path  $\alpha$ 
11:   return  $\theta_{\text{super}}$ 
```

Giai đoạn 2: Tìm kiếm kiến trúc bằng Tối ưu hóa Bayesian

Sau khi có θ_{super} , AutoShot tiến hành tìm kiếm kiến trúc tối ưu bằng Tối ưu hóa Bayesian (BO) với mô hình đại diện Quá trình Gauss (GP). BO phù hợp với bài toán này vì: (1) không gian kiến trúc rời rạc và không khả vi, (2) mỗi lần đánh giá tuy rẻ hơn huấn luyện đầy đủ nhưng vẫn tốn thời gian, và (3) cần tìm cực trị toàn cục trong không gian 83.9M điểm với ngân sách hữu hạn.

GP với kernel Hamming (đo khoảng cách giữa hai chuỗi cấu hình theo số vị trí khác biệt) duy trì phân phối hậu nghiệm $f(\alpha) \mid \mathcal{D}_n \sim \mathcal{GP}(\mu_n(\alpha), \sigma_n^2(\alpha))$ dựa trên các quan sát đã thu thập. Hàm thu thập *Probability of Feasibility* (PoF) hướng dẫn lựa chọn ứng viên tiếp theo:

$$\text{PoF}(\alpha) = \Phi\left(\frac{\mu_n(\alpha) - f_{\text{best}}}{\sigma_n(\alpha)}\right), \quad (3.6)$$

PoF ổn định hơn EI trong không gian rời rạc có nhiều vì chỉ quan tâm đến xác suất vượt mốc tốt nhất, không bị thiên lệch bởi dự đoán μ_n quá lạc quan ở vùng phương sai cao. Tổng cộng 4800 đánh giá (0.0057% của 83.9M kiến trúc) đủ để tìm cấu hình gần tối ưu.

Thuật toán 3 Bayesian Architecture Search

```
1: function BAYESIANSEARCH( $\theta_{\text{super}}, T = 100$ )
2:    $\mathcal{D} \leftarrow \emptyset$ ;  $f_{\text{best}} \leftarrow -\infty$ 
3:    $GP \leftarrow \text{InitializeGaussianProcess}(\text{kernel} = \text{Hamming})$ 
4:    $\triangleright$  Phase 1: Random Exploration (20 epochs)
5:   for  $t = 1 \dots 20$  do
6:     for  $i = 1 \dots 48$  do
7:        $\alpha \leftarrow \text{SampleRandom}(\mathcal{S})$ 
8:        $F1 \leftarrow \text{QuickEvaluate}(\alpha, \theta_{\text{super}}, \mathcal{D}_{\text{val}})$ 
9:        $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\alpha, F1)\}$ ;  $f_{\text{best}} \leftarrow \max(f_{\text{best}}, F1)$ 
10:       $GP.\text{Update}(\mathcal{D})$ 
11:    $\triangleright$  Phase 2: Bayesian Optimization (80 epochs)
12:   for  $t = 21 \dots T$  do
13:     for  $i = 1 \dots 48$  do
14:        $(\mu, \sigma) \leftarrow GP.\text{Predict}(\mathcal{S})$   $\triangleright$  Posterior distribution over
       search space
15:        $\alpha_{\text{next}} \leftarrow \arg \max_{\alpha \in \mathcal{S}} \Phi\left(\frac{\mu(\alpha) - f_{\text{best}}}{\sigma(\alpha)}\right)$ 
16:        $F1 \leftarrow \text{QuickEvaluate}(\alpha_{\text{next}}, \theta_{\text{super}}, \mathcal{D}_{\text{val}})$ 
17:        $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\alpha_{\text{next}}, F1)\}$ ;  $f_{\text{best}} \leftarrow \max(f_{\text{best}}, F1)$ 
18:        $GP.\text{Update}(\mathcal{D})$ 
19:    $\alpha^* \leftarrow \arg \max_{(\alpha, F1) \in \mathcal{D}} F1$ 
20:   return  $\alpha^*$ 
```

Chi phí tính toán

Tổng thể, quy trình AutoShot đắt hơn TransNetV2 vì phải trả chi phí tìm kiếm trước khi có mô hình cuối. Bảng 3.9 chuẩn hóa các con số theo cùng dải ước lượng được dùng trong phần so sánh.

Bảng 3.9: Chi phí tính toán ước tính của từng pha trong AutoShot

Pha	Mô tả	Phần cứng	Thời gian ước tính
1. Huấn luyện SuperNet	12 epoch, single-path	$8 \times$ V100	$\approx$ 12–16 giờ
2. Tìm kiếm kiến trúc	4800 đánh giá (GP + PoF)	$8 \times$ V100	$\approx$ 40–50 giờ
3. Huấn luyện lại (Retraining)	12 epoch với α^*	$1 \times$ V100	$\approx$ 12 giờ
4. Chứng cất tri thức (KD)	12 epoch, student học từ teacher	$1 \times$ V100	$\approx$ 12 giờ
5. Ghép trọng số	Tính entropy + nội suy trọng số	CPU	< 1 giờ
Tổng			$\approx$ 76–91 giờ

So với TransNetV2 ($\approx$ 17 giờ, 1 GPU), AutoShot tốn 4–5 lần thời gian và đòi hỏi nhiều GPU ở giai đoạn tìm kiếm. Đây là đánh đổi cốt lõi của NAS: chi phí trả trước lớn, nhưng mô hình cuối cùng có chi phí suy diễn xấp xỉ TransNetV2 vì chỉ còn một kiến trúc con α^* được chọn ra. SuperNet cần $\approx$ 16 GB VRAM trong pha huấn luyện, còn mô hình cuối chỉ cần $\approx$ 2 GB.

3.4.4 Huấn luyện lại và tinh chỉnh mô hình

Sau khi BO chọn được kiến trúc α^* , AutoShot không dùng trực tiếp trọng số chia sẻ (shared) của SuperNet làm mô hình cuối. Kiến trúc này được huấn luyện lại từ đầu trong 12 epoch với cùng hàm mục tiêu như TransNetV2 (phương trình (3.3)). Bước huấn luyện lại giúp loại bỏ nhiễu do chia sẻ trọng số (weight sharing) gây ra: trong SuperNet, mỗi đường đi chỉ được cập nhật rời rạc theo lấy mẫu; trong mô hình cuối, toàn bộ tham số của α^* được tối ưu liên tục cho một kiến trúc cố định.

Sau khi huấn luyện lại, AutoShot áp dụng hai kỹ thuật tinh chỉnh không làm thay đổi kiến trúc: chứng cất tri thức và Weight Grafting. Vì vậy, phần này cần được hiểu là giai đoạn *hoàn thiện trọng số*, không phải tiếp tục tìm kiếm kiến trúc.

chưng cất tri thức — trích xuất tri thức

chưng cất tri thức (KD) [8] sử dụng mô hình ứng viên tốt nhất sau bước huấn luyện lại làm *giáo viên* (teacher), hướng dẫn quá trình học của *học sinh* (student) — cũng là kiến trúc α^* nhưng khởi tạo ngẫu nhiên. Ý tưởng cốt lõi: thay vì học từ nhãn cứng (nhãn cứng) nhị phân $\{0, 1\}$, student học từ nhãn mềm (nhãn mềm) của teacher.

Nhãn mềm $\tilde{y}_{i,t}^{(j)}$ là xác suất dự đoán của teacher tại khung t của chuỗi i , nhánh $j \in \{1, 2\}$. Hàm mất mát KD:

$$\mathcal{L}_{\text{distill}} = -\frac{1}{KM} \sum_{i=1}^K \sum_{t=1}^M \left[\lambda_1 \cdot \tilde{y}_{i,t}^{(1)} \log \hat{y}_{i,t}^{(1)} + \lambda_2 \cdot \tilde{y}_{i,t}^{(2)} \log \hat{y}_{i,t}^{(2)} \right], \quad (3.7)$$

trong đó $\tilde{y}^{(j)}$ là nhãn mềm của teacher (cố định, không có gradient qua teacher), $\hat{y}^{(j)}$ là dự đoán của student, và $\lambda_1 = 5.0$, $\lambda_2 = 0.1$ như trong phương trình (3.3).

So sánh với phương trình (3.3), sự khác biệt duy nhất là nhãn ground-truth $y^{(j)}$ được thay bằng nhãn mềm $\tilde{y}^{(j)}$ từ teacher. Nhãn mềm mang nhiều thông tin hơn nhãn nhị phân: chúng phản ánh độ không chắc chắn của teacher, đặc biệt tại các khung hình thuộc vùng chuyển cảnh dần hay các chuyển cảnh đột ngột có nền màu tương đồng. Nhờ đó, student học được phân phối xác suất trơn tru hơn, ít kích hoạt cực đoan hơn và bền vững hơn trước các biến thể rìa ranh giới — đây là cốt lõi của "giảng dạy về sự không chắc chắn" trong KD.

Trong AutoShot, teacher và student có *cùng kiến trúc* α^* — đây là trường hợp KD tự học (self-distillation). Khác với KD truyền thống (teacher lớn hơn student), tự học giúp student thoát khỏi cực trị cục bộ mà retraining trước đó có thể đã rơi vào, do điểm khởi đầu ngẫu nhiên khác nhau.

Weight Grafting — ghép trọng số theo entropy

Weight Grafting là kỹ thuật kết hợp trọng số từ hai mô hình dựa trên entropy của phân phối trọng số, giả định rằng lớp có entropy trọng số cao hơn đã học được biểu diễn phong phú và đa dạng hơn.

Cho hai mô hình M_1 (sau retraining) và M_2 (sau KD) với trọng số lớp l lần lượt là $W_1^{(l)}$ và $W_2^{(l)}$, entropy được ước tính bằng histogram $B = 10$ bin trên phân phối của các giá trị trọng số:

$$H(W^{(l)}) = - \sum_{b=1}^B p_b \log p_b, \quad p_b = \frac{|\{w \in W^{(l)} : w \in \text{bin}_b\}|}{|W^{(l)}|}, \quad (3.8)$$

với p_b là xác suất ước tính của bin b trong histogram. Hệ số ghép $\alpha^{(l)}$ xác định tỉ lệ đóng góp của M_2 tại lớp l theo công thức arctan liên tục:

$$\alpha^{(l)} = A \cdot \arctan(c \cdot (H(W_2^{(l)}) - H(W_1^{(l)}))) + 0.5, \quad (3.9)$$

trong đó $A = 0.4$ và $c = 1.0$ là siêu tham số điều khiển độ nhạy và tốc độ chuyển tiếp. Hàm arctan đảm bảo $\alpha^{(l)} \in [0.5 - A\pi/2, 0.5 + A\pi/2] \approx [0.5 - 0.628, 0.5 + 0.628]$, giới hạn ảnh hưởng tối đa của bất kỳ mô hình nào. Trọng số ghép cuối cùng:

$$W_{\text{grafted}}^{(l)} = \alpha^{(l)} \cdot W_2^{(l)} + (1 - \alpha^{(l)}) \cdot W_1^{(l)}. \quad (3.10)$$

Khi $H(W_2^{(l)}) > H(W_1^{(l)})$, hàm arctan dương, $\alpha^{(l)} > 0.5$ — ưu tiên trọng số M_2 tại lớp đó; ngược lại ưu tiên M_1 . Điều này cho phép Weight Grafting thích ứng linh hoạt theo từng lớp: lớp nào M_2 học tốt hơn thì dùng nhiều M_2 , và ngược lại.

Hàm arctan đảm bảo tính bão hòa: khi chênh lệch entropy rất lớn, $\alpha^{(l)}$ tiệm cận $0.5 \pm A\pi/2$ thay vì để một mô hình hoàn toàn lấn át mô hình kia. Tham số c điều chỉnh độ dốc chuyển tiếp.

Một điểm thực tế quan trọng: trong AutoShot, Weight Grafting được áp dụng giữa ba mô hình $[\theta_{\text{retrain}}, \theta_{\text{student}}, \theta_{\text{retrain}}]$ (theo thứ tự ghép), không chỉ hai mô hình. Điều này tạo ra một chuỗi ghép tuần tự, trong đó kết quả ghép của hai mô hình đầu tiên tiếp tục được ghép với mô hình thứ ba. Kết hợp Weight Grafting sau KD mang lại cải thiện thêm $\approx 0.3\%$ F1 trên tập SHOT.

3.4.5 Kiến trúc tối ưu của AutoShot

Nhóm tác giả tiến hành tìm kiếm hai lần với hai tiêu chí đánh giá khác nhau, thu được hai kiến trúc có đặc điểm bổ sung cho nhau: AutoShot@F1 tối ưu cân bằng precision–recall, còn AutoShot@Precision ưu tiên giảm dương tính giả.

Bảng 3.10 tổng hợp kiến trúc tìm được cho hai tiêu chí:

Bảng 3.10: Kiến trúc tối ưu của AutoShot theo hai tiêu chí tối ưu

Block/Thông số	AutoShot@F1 (F1=84.1%)	AutoShot@Precision (P=93.9%)
Block 1	DDCNNV2 ($4F$, $nd = 4$)	DDCNNV2 ($12F$, $nd = 4$)
Block 2–4	DDCNNV2A ($4F$, $nd = 5$) $\times 3$	V2($8F$, 4), V2B(4), V2C(4)
Block 5	DDCNNV2 ($12F$, $nd = 5$)	DDCNNV2B ($nd = 5$)
Block 6	DDCNNV2 ($8F$, $nd = 5$)	DDCNNV2B ($nd = 4$)
Block 7 (Transformer)	0 lớp attention	0 lớp attention
FLOPs	37 GMACs	30 GMACs

Cả hai kiến trúc đều chọn 0 lớp Transformer (xác nhận tích chập giãn nở đủ để mô hình hóa phụ thuộc thời gian trong video ngắn). AutoShot@F1 thiên về DDCNNV2A (shared spatial) ở lớp giữa, trong khi AutoShot@Precision dùng nhiều DDCNNV2B (Add) ở lớp sau — biểu diễn bảo thủ hơn, ít kích hoạt cực đoan, dẫn đến giảm dương tính giả. Điều này cho thấy không gian tìm kiếm đủ đa dạng để NAS tìm kiến trúc chuyên biệt cho từng tiêu chí.

3.4.6 So sánh với TransNetV2

Tiểu mục này đặt TransNetV2 và AutoShot cạnh nhau nhằm tách bạch hai lớp đóng góp: các thành phần AutoShot kế thừa trực tiếp từ TransNetV2 và các thay đổi do quy trình NAS của AutoShot gốc mang lại. Cách nhìn này quan trọng vì AutoShot không thay toàn bộ quy trình, mà giữ lại nhiều quyết định thiết kế hiệu quả của TransNetV2 rồi chỉ tối ưu những điểm có khả năng ảnh hưởng mạnh đến phân phối SHOT.

Bảng tổng hợp

Bảng 3.11 tập trung vào các chiều kỹ thuật cốt lõi: cách thiết kế kiến trúc, không gian tìm kiếm, thành phần giữ nguyên, chi phí huấn luyện và hiệu năng chính trên SHOT.

Bảng 3.11: So sánh tổng hợp TransNetV2 và AutoShot

Đặc điểm	TransNetV2	AutoShot
Cách thiết kế kiến trúc	Thiết kế thủ công, cố định	Tìm kiếm tự động bằng NAS
Không gian kiến trúc	1 kiến trúc cố định	83.9M ứng viên
Khối tích chập chính	DDCNNV2 cố định	DDCNNV2/A/B/C được chọn theo từng vị trí
Thành phần giữ nguyên	Sliding window, similarity branch, two-head output	Kế thừa các thành phần này từ TransNetV2
Chiến lược tìm kiếm	Không có	Single-Path One-Shot + Bayesian Optimization
Kỹ thuật sau tìm kiếm	Huấn luyện trực tiếp	Retraining, chưng cất tri thức và Weight Grafting
Chi phí huấn luyện	≈ 17 giờ trên $1 \times V100$	$\approx 76\text{--}91$ giờ trên $8 \times V100$
Quy mô tham số	$\approx 6.5\text{M}$	$\approx 6.7\text{M}$
Hiệu năng chính trên SHOT	$F1 = 0.7993$ (79.9%)	$F1 = 0.8405$ (84.1%)
Precision trên SHOT	Khoảng 80%	93.9% với AutoShot@Precision

Nhận xét ưu và nhược điểm tương đối

Ưu điểm của AutoShot so với TransNetV2. Mức tăng từ 0.7993 lên 0.8405 F1 trên SHOT là đáng kể, nhất là khi AutoShot không lớn hơn TransNetV2 theo số tham số. Điểm chính không nằm ở việc mở rộng năng lực mô hình, mà ở việc thay đổi cách chọn kiến trúc: NAS tìm cấu hình khối tích chập phù hợp hơn với phân phối video ngắn của SHOT. AutoShot@Precision cũng cho thấy cùng một không gian kiến trúc có thể được tối ưu theo mục tiêu khác, đạt precision 93.9% khi cần giảm dương tính giả trong hệ thống biên tập bán tự động.

Hạn chế của AutoShot. Đánh đổi chính là chi phí NAS và độ khó tái

lập. Quy trình AutoShot cần nhiều pha hơn TransNetV2, tiêu tốn khoảng 76–91 giờ trên 8 GPU V100 so với khoảng 17 giờ trên 1 GPU V100 của TransNetV2. Ngoài ra, kiến trúc tìm được gắn chặt với mục tiêu và tập validation dùng trong tìm kiếm; khả năng tổng quát hóa sang các bộ dữ liệu khác được phân tích riêng ở Chương 5.

Tóm lại, AutoShot kế thừa phần lớn quy trình hiệu quả của TransNetV2 và chỉ thay đổi cơ chế lựa chọn mạng xương sống. Điểm đóng góp chính không phải là làm mô hình lớn hơn, mà là làm cho kiến trúc khớp hơn với phân phối video ngắn. Đây là nền tảng để AutoShotV2 ở mục tiếp theo đóng băng mạng xương sống AutoShot@F1 và tập trung cải tiến tầng phân loại cùng hậu xử lý, thay vì chạy lại toàn bộ NAS.

3.5 Biến thể AutoShotV2 — Cải tiến tầng phân loại và hậu xử lý

3.5.1 Động lực và chiến lược tổng thể


AutoShot@F1 đạt $F1 = 0.8405$ với BCE chuẩn và nhãn one-hot. Tầng phân loại vẫn còn hai hạn chế: (i) mất cân bằng lớp nghiêm trọng (ranh giới chiếm $<1\%$ khung hình); (ii) tín hiệu cứng nhắc không chịu sai lệch chú thích. AutoShotV2 áp dụng chiến lược **đóng băng mạng xương sống + huấn luyện lại tầng phân loại (ClassificationHead)**: khóa toàn bộ trọng số AutoShot@F1, huấn luyện bộ phân lớp mới từ đầu trên các đặc trưng đã được lưu bộ nhớ đệm. Quyết định này được thúc đẩy bởi ba lý do thực tế: (a) NAS đã tối ưu mạng xương sống với chi phí lớn (76–91 giờ trên $8 \times V100$, Bảng 3.9), nên kết quả không nên bị mất đi qua một lần huấn luyện toàn mạng nữa; (b) đóng băng mạng xương sống cô lập đóng góp của tầng phân loại, làm mọi cải thiện F1 đều có thể quy về thiết kế tầng phân loại; (c) chỉ huấn luyện tầng phân loại trên đặc trưng đã bộ nhớ đệm giúp giảm chi phí huấn luyện lại từ hàng chục giờ xuống còn vài chục phút trên một GPU phổ thông, cho phép thử nghiệm nhanh nhiều cấu hình phân rã.

3.5.2 Kiến trúc ClassificationHead

Tương tự AutoShot, AutoShotV2 thiết kế một ClassificationHead hai nhánh song song đặt sau lớp trích xuất đặc trưng 4864-D:

1. **fc1**: $\text{Linear}(4864 \rightarrow 1024) + \text{ReLU}$ — nén đặc trưng về không gian thấp hơn.
2. **Dropout**($p = 0.5$) — chính quy hóa để tránh quá khớp trên tập huấn luyện nhỏ.
3. **cls_layer1**: $\text{Linear}(1024 \rightarrow 1)$ — nhánh chính với **nhãn one-hot**, học định vị ranh giới chính xác.
4. **cls_layer2**: $\text{Linear}(1024 \rightarrow 1)$ — nhánh phụ với **nhãn many-hot**, học ngữ cảnh vùng quanh ranh giới.

Toàn bộ đặc trưng mạng xương sống được **tính trước và lưu cache** vào file `.pickle` trước khi huấn luyện, giúp mỗi epoch chỉ cần chạy qua bộ phân lớp nhỏ thay vì toàn mạng mạng xương sống 55 MB, tăng tốc đáng kể vòng lặp huấn luyện.



Hình 3.7: Kiến trúc ClassificationHead trong AutoShotV2. Head nhận đặc trưng 4864-D từ mạng xương sống (đóng băng) và sinh hai đầu ra song song: nhánh one-hot định vị ranh giới chính xác và nhánh many-hot học ngữ cảnh vùng biên.

3.5.3 Focal Loss – giải quyết mất cân bằng lớp

Trong video ngắn, khung hình tại ranh giới chiếm chưa đến 1% tổng số khung hình. Nếu xử lý đây như bài toán phân loại nhị phân trên từng khung, hàm Binary Cross-Entropy (BCE) chuẩn bị chi phối bởi hàng loạt mẫu âm để phân loại:

$$\mathcal{L}_{\text{BCE}} = -[y \log(p) + (1 - y) \log(1 - p)] \quad (3.11)$$

Đặt p_t là xác suất gán cho lớp đúng ($p_t = p$ nếu $y = 1$; $p_t = 1 - p$ nếu $y = 0$), BCE viết gọn thành $\mathcal{L}_{\text{BCE}} = -\log(p_t)$. Khi tổng hợp giá trị mất mát (loss) trên toàn bộ lô (batch), các mẫu âm dễ (mẫu âm dễ - khung không có chuyển cảnh, rất dễ phân loại) áp đảo về số lượng và kéo gradient theo hướng “luôn dự đoán không có ranh giới”.

Khác với AutoShot gốc dùng BCE có trọng số λ_1, λ_2 trên nhãn one-hot (phương trình (3.3)), AutoShotV2 thay BCE bằng **Focal Loss** [10] — được thiết kế chuyên cho mất cân bằng lớp trong bài toán phát hiện — với nhân tử động $(1 - p_t)^\gamma$ làm giảm trực tiếp đóng góp của các mẫu âm dễ ngay trong từng mẫu, thay vì chỉ cân bằng giữa hai nhánh:

$$\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (3.12)$$

Nhân tử $(1 - p_t)^\gamma$ là điểm mấu chốt. Với một *mẫu âm dễ* ($p_t \approx 0.99$), nhân tử gần bằng 0, đóng góp vào tổng giá trị mất mát gần như biến mất. Với một *mẫu khó* (*hard example*) — khung ranh giới chỉ dự đoán được $p_t \approx 0.3$ — nhân tử vẫn lớn, buộc mô hình tiếp tục học. Focal Loss ưu tiên các mẫu khó: ranh giới mờ, chuyển cảnh dần, hay thay đổi ánh sáng dễ gây nhầm lẫn. Nếu $\gamma = 0$, Focal Loss quay về BCE có trọng số α .

Tham số $\gamma \in \{1.0, 2.0\}$ và $\alpha \in \{0.5, 0.75\}$ được chọn qua **tìm kiếm lưới** (8 tổ hợp), đánh giá theo F1 trên tập xác thực. Cấu hình tốt nhất: $\gamma = 1.0$, $\alpha = 0.5$. Khác với BCE có trọng số (BCE có trọng số - chỉ điều chỉnh trọng số tĩnh giữa hai lớp) hoặc hàm mất mát cân bằng lớp (hàm mất mát cân bằng lớp - dựa trên số mẫu hữu hiệu), Focal Loss điều chỉnh *động* theo độ khó của từng mẫu — phù hợp với SBD nơi mức độ khó biến thiên mạnh giữa chuyển cảnh đột ngột, chuyển cảnh dần và các trường hợp

ánh sáng đột biến. Trong tìm kiếm lưới, $\gamma = 1.0$ thắng $\gamma = 2.0$ do nhánh many-hot (Mục 3.5.4) đã cung cấp thêm tín hiệu giám sát cho vùng biên, nên hệ số làm sắc quá mạnh khiến gradient ở các khung biên bị triệt tiêu sớm.

3.5.4 Nhãn many-hot — giám sát vùng biên

Nhãn one-hot chuẩn chỉ gán giá trị 1 tại đúng một khung hình ranh giới và 0 cho tất cả còn lại. Cách biểu diễn này chính xác về định vị, nhưng quá cứng nhắc trong thực tiễn SBD vì hai lý do: (i) chú thích thủ công có thể lệch ± 1 frame so với ranh giới thực sự; (ii) chuyển cảnh dần kéo dài trên nhiều frame, nên các khung lân cận ranh giới cũng mang tín hiệu chuyển cảnh đáng kể.

AutoShotV2 bổ sung một nhánh giám sát phụ với **nhãn many-hot** [13]: tất cả các khung trong phạm vi ± 1 frame quanh ranh giới đều được coi là dương:

$$y_{\text{many-hot}}[t] = \begin{cases} 1, & \exists t_b \text{ sao cho } |t - t_b| \leq 1 \\ 0, & \text{ngược lại} \end{cases} \quad (3.13)$$


Hàm mất mát kết hợp hai nhánh với trọng số khác nhau:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{focal}}(\hat{y}_1, y_{\text{one-hot}}) + 0.3 \cdot \mathcal{L}_{\text{focal}}(\hat{y}_2, y_{\text{many-hot}}) \quad (3.14)$$

Nhánh one-hot giữ vai trò chính: định vị ranh giới sắc nét tại đúng thời điểm chuyển cảnh. Nhánh many-hot đóng vai trò phụ (hệ số 0.3): dạy mô hình rằng các khung lân cận ranh giới là những mẫu “gần đúng” và không nên bị phạt nặng khi dự đoán lệch nhẹ. Hệ số 0.3 được chọn nhỏ hơn 1 để nhánh phụ hỗ trợ mà không lấn át định vị chính xác.

Bán kính ± 1 frame được chọn căn cứ vào phân phối sai số chú thích thực tế trên SHOT: phần lớn ranh giới thủ công được đánh lệch không quá một khung so với chuyển cảnh đột ngột thật, và chuyển cảnh dần thường kéo dài 3–5 khung sao cho ba khung trung tâm $\{t-1, t, t+1\}$ mang tín hiệu chuyển cảnh rõ nhất. Mở rộng sang ± 2 frame trong thử nghiệm sơ bộ làm tăng nhiễu giám sát vì các khung biên xa hơn (như $t \pm 2$) thường đã

thuộc shot lân cận, gây nhầm chuyển cảnh đột ngột với chuyển cảnh dần và làm giảm precision.



Hình 3.8: Minh họa nhãn one-hot và many-hot. Nhãn one-hot chỉ gán 1 tại đúng khung ranh giới t ; nhãn many-hot mở rộng thêm $t \pm 1$, cung cấp tín hiệu gradient dày đặc hơn quanh vùng ranh giới.

3.5.5 Gaussian Smoothing — triệt tiêu nhiễu đơn lẻ

Sau khi mô hình sinh chuỗi xác suất $p[t]$, tín hiệu này thường chứa các đỉnh nhọn hẹp do nhiễu cục bộ: một khung đơn lẻ có xác suất cao bất thường vì flash sáng, rung máy, hoặc biến đổi màu sắc đột ngột. Nếu ngưỡng hóa trực tiếp, các đỉnh nhiễu dễ bị nhận nhầm là ranh giới cảnh. AutoShotV2 áp dụng **Gaussian smoothing 1D** với $\sigma = 2.0$ lên chuỗi xác suất trước bước ngưỡng hóa:

$$\hat{p}[t] = \sum_k G_\sigma(k) \cdot p[t - k], \quad G_\sigma(k) = \frac{1}{\sqrt{2\pi}\sigma} e^{-k^2/(2\sigma^2)} \quad (3.15)$$

Phép biến đổi này là *lấy trung bình có trọng số theo trục thời gian*: xác suất tại t sau làm mượt phụ thuộc vào các khung lân cận, với trọng số giảm dần theo dạng chuông Gaussian. Hạt nhân Gaussian được chuẩn hóa nên chủ yếu *phân phối lại* xác suất trong vùng lân cận.

Nguyên tắc hoạt động: ranh giới thật tạo phản hồi nhất quán trên vài khung liên tiếp — sau smoothing, các khung “hỗ trợ lẫn nhau” và đỉnh xác suất được giữ lại. Nhiễu đơn lẻ không được hàng xóm ủng hộ bị kéo xuống đáng kể. Tham số $\sigma = 2.0$ được chốt sau khi quét $\sigma \in \{1.0, 1.5, 2.0, 2.5, 3.0\}$ trên tập xác thực của SHOT: giá trị nhỏ hơn ($\sigma \leq 1.5$) chưa đủ triệt tiêu flash, trong khi giá trị lớn hơn ($\sigma \geq 2.5$) làm phẳng cả các đỉnh ranh giới thật và đẩy ngưỡng tối ưu xuống vùng quá nhỏ, kém ổn định. So với bộ lọc trung vị (median filter) — một lựa chọn hậu xử lý phổ biến khác — hạt

nhân Gaussian (kernel Gaussian) giữ được dạng đỉnh khi ranh giới được nhiều khung liên tiếp hỗ trợ và tránh hiện tượng cắt phẳng đột ngột, phù hợp hơn với phân phối xác suất sigmoid của tầng phân loại.

3.5.6 Hiệu chỉnh nhiệt độ (Temperature Scaling) — hiệu chỉnh xác suất

Sau huấn luyện, phân phối xác suất đầu ra của mô hình có thể chưa được hiệu chỉnh tốt (poorly calibrated): mô hình có thể *thiếu tự tin* (*under-confident*) (xác suất bị nén về gần 0.5 dù nhiều mẫu khá chắc chắn) hoặc *quá tự tin* (*over-confident*). Trong SBD, hiệu chỉnh xác suất trực tiếp ảnh hưởng đến việc chọn ngưỡng tối ưu.

AutoShotV2 áp dụng **hiệu chỉnh nhiệt độ** [5]: tìm hệ số vô hướng T^* tối thiểu hóa mất mát NLL (Negative Log-Likelihood) trên tập xác thực mà không huấn luyện lại bất kỳ tham số nào:

$$T^* = \arg \min_{T \in [0.1, 10.0]} \mathcal{L}_{\text{BCE}}\left(\sigma\left(\frac{z}{T}\right), y\right) \quad (3.16)$$

trong đó z là logit trước sigmoid. Điểm quan trọng: hiệu chỉnh nhiệt độ *không thay đổi thứ tự tương đối* giữa các dự đoán (phép chia cho $T > 0$ là đơn điệu), chỉ hiệu chỉnh mức độ tự tin. Nếu $T > 1$, phân phối bị làm phẳng; nếu $T < 1$, phân phối trở nên sắc hơn và các giá trị bị đẩy xa khỏi 0.5.

Giá trị tối ưu trên tập SHOT: $T^* = 0.3878 < 1$, cho thấy mô hình đang *thiếu tự tin* (*under-confident*) — nhiều dự đoán đúng nhưng xác suất chưa đủ “dứt khoát”. Chia logit cho $T^* < 1$ làm sắc hóa phân phối, đẩy các dự đoán rõ ràng ra xa vùng trung tính. Hệ quả: ngưỡng tối ưu dịch từ 0.296 (AutoShot) xuống 0.02 (AutoShotV2).

Khoảng tìm kiếm $T \in [0.1, 10.0]$ được chọn theo khuyến nghị của Guo et al. [5] cho bài toán phân loại nhị phân: cận dưới 0.1 cho phép sắc hóa rất mạnh khi mô hình thiếu tự tin (*under-confident*), còn cận trên 10.0 phủ trường hợp quá tự tin (*over-confident*) mà không gặp rủi ro chia cho giá trị quá lớn làm gradient triệt tiêu. So với hiệu chỉnh Platt (Platt scaling - học hai tham số affine a, b trên logit) hoặc hồi quy đơn điệu (isotonic

regression - hàm bậc thang không tham số), hiệu chỉnh nhiệt độ chỉ có một tham số duy nhất nên không có nguy cơ quá khớp (quá khớp) trên tập xác thực nhỏ và giữ nguyên thứ tự xếp hạng dự đoán — một tính chất then chốt để ngưỡng hóa nhị phân của SBD vẫn ổn định sau hiệu chỉnh.

3.5.7 Quy trình huấn luyện lại và thuật toán tổng thể

Tầng phân loại (ClassificationHead) được huấn luyện lại theo chiến lược hai pha [12]: khởi động tuyến tính trong 4 epoch (tốc độ học - LR từ 0 đến 10^{-5}) rồi giảm nhiệt cosine đến tối đa 20 epoch. Cấu hình chạy cuối không dùng cơ chế dừng sớm, nhằm giữ cùng ngân sách huấn luyện cho các biến thể thực nghiệm phân rã.

3.6 Tổng kết chương

Chương này đã trình bày hướng tiếp cận kế thừa AutoShot và cải tiến ở tầng đầu ra để hình thành AutoShotV2. Các nội dung chính gồm nền tảng NAS và TransNetV2, mô hình AutoShot gốc, kiến trúc tầng phân loại mới, Focal Loss, nhãn many-hot, Gaussian smoothing, hiệu chỉnh nhiệt độ và quy trình huấn luyện lại. Chương 4 tiếp theo mô tả dữ liệu, thiết lập thực nghiệm và kết quả đánh giá.

Chương 4

BỘ DỮ LIỆU VÀ THỰC NGHIỆM

Chương này tập trung vào dữ liệu và kết quả thực nghiệm. Nội dung chính gồm đặc điểm của bộ dữ liệu SHOT, hai bộ dữ liệu đánh giá bổ sung BBC Planet Earth và ClipShots, các chỉ số Precision/Recall/F1, sau đó trình bày kết quả định lượng và nhận xét chính trên từng bộ dữ liệu.

4.1 Bộ dữ liệu SHOT

SHOT [23] (Short Video Shot Boundary Detection Dataset) là bộ dữ liệu công khai dành cho tác vụ phát hiện ranh giới cảnh quay (shot boundary detection) trong video ngắn. Các nền tảng video ngắn như TikTok hay Instagram Reels đã thay đổi thói quen tiêu thụ nội dung. Nhu cầu phân tích video chính xác về mặt thời gian là cấp thiết. SHOT cung cấp dữ liệu chuẩn cho video có nhịp độ nhanh và nội dung cô đọng.

Phần lớn các bộ dữ liệu phát hiện biên cảnh (SBD) hiện có như BBC Planet Earth [2] chỉ chứa phim tài liệu hoặc talk show với cảnh quay tĩnh và nhịp độ chậm. Ngay cả bộ dữ liệu lớn ClipShots cũng chủ yếu chứa các video dài (trung bình 237 giây). SHOT ra đời để lấp đầy khoảng trống này với tư cách là bộ dữ liệu công khai đầu tiên dành riêng cho video ngắn, bao gồm 853 video hoàn chỉnh và 11.606 chú thích cảnh quay, mang tính thách thức cao hơn về nhịp độ và hiệu ứng hình ảnh.

4.1.1 Chi tiết bộ dữ liệu


- **Tên bộ dữ liệu:** SHOT (Short Video Shot Boundary Detection Dataset)
- **Quy mô:** 853 video ngắn và 11.606 chú thích ranh giới cảnh quay

- **Tổng số khung hình:** 960.794 khung hình
- **Tập kiểm tra:** 200 video với 2.716 chú thích chất lượng cao; chuyên gia kiểm duyệt hai vòng
- **Nguồn dữ liệu:** Video từ một nền tảng video ngắn phổ biến
- **Quyền riêng tư:** Làm mờ khuôn mặt bằng công cụ phát hiện khuôn mặt
- **Phương pháp gán nhãn:** Dùng hình thu nhỏ 48×27 cho mỗi khung hình; số thứ tự khung hình hiển thị thích ứng để giảm công sức kiểm tra

4.1.2 Phân tích bộ dữ liệu

SHOT được phân tích dựa trên các thách thức đặc thù của video ngắn:


- **Chuyển cảnh dần phức tạp (Complex Gradual Transitions):** Kết hợp nhiều hiệu ứng chuyển cảnh chồng chéo thay vì cắt cảnh dứt khoát.
- **Cấu trúc tam phân (Ternary Structure):** Video dọc thường giữ nguyên phần trên và dưới (chứa liên kết/thương hiệu), chỉ thay đổi nội dung ở giữa, gây khó khăn cho việc phát hiện.
- **Cảnh ảo (Virtual Scenes):** Các video game với hiệu ứng hình ảnh phóng đại và biến đổi liên tục.



Hình 4.1: Minh họa các thách thức đặc thù trong SHOT: (Hàng 1) Chuyển cảnh dần phức tạp, (Hàng 2) Cấu trúc tam phân, và (Hàng 3) Cảnh ảo.

Sự khác biệt giữa video ngắn và video truyền thống không chỉ nằm ở thời lượng mà còn ở nhịp độ và phong cách hậu kỳ (so sánh chi tiết xem Bảng 4.1 ở Mục 4.2.3). Các thống kê chính phản ánh tính chất ngắn và nhanh của bộ dữ liệu:

- **Độ dài trung bình video:** 39.5 giây
- **Độ dài trung bình cảnh:** 2.59 giây
- **Phân bố thời lượng:** 90% video có độ dài dưới một phút
- **Tốc độ chuyển cảnh:** Hầu hết các cảnh trong tập kiểm tra kéo dài dưới 5 giây; video ngắn có nhịp độ sự kiện nhanh hơn video truyền thống



Hình 4.2: Sự phân bố độ dài video (trên) và độ dài shot (dưới). Có thể thấy sự chênh lệch rõ rệt: shot trong SHOT tập trung dày đặc ở vùng dưới 5 giây.

4.1.3 Tóm tắt bộ dữ liệu SHOT

Trong khóa luận, SHOT là bộ dữ liệu trung tâm để đánh giá hiệu quả trên video ngắn. Các kết quả trên SHOT được dùng để so sánh trực tiếp với TransNetV2, AutoShot gốc và các biến thể AutoShotV2; các kết quả trên BBC và ClipShots được dùng để kiểm tra khả năng tổng quát hóa sang miền dữ liệu khác. Với các đặc điểm độc đáo phản ánh đúng thực tế của video ngắn và quy trình gán nhãn chất lượng cao, SHOT không chỉ là một chuẩn mực đánh giá mới mà còn là một tài nguyên quý giá để huấn luyện các mô hình SBD thế hệ tiếp theo. Các kết quả thực nghiệm chi tiết trên SHOT và các bộ dữ liệu bổ sung được trình bày ở các mục kết quả phía sau.

4.2 Các bộ dữ liệu đánh giá bổ sung

Ngoài bộ dữ liệu SHOT dành riêng cho video ngắn, các nghiên cứu về phát hiện ranh giới cảnh quay thường được đánh giá trên nhiều bộ dữ liệu chuẩn khác nhau để kiểm tra khả năng tổng quát hóa. Phần này giới thiệu chi tiết hai bộ dữ liệu phổ biến: BBC Planet Earth và ClipShots. Những bộ dữ liệu này đại diện cho các miền nội dung và thách thức khác nhau, giúp đánh giá toàn diện hiệu năng của các mô hình SBD.

4.2.1 Bộ dữ liệu BBC Planet Earth

BBC Planet Earth [2] gồm 11 tập phim tài liệu thiên nhiên (50 phút/tập, 4.900 shot, shot TB 6.57 giây). Nội dung chất lượng cao với camera mượt mà (panning, zooming) và phong cách biên tập nghệ thuật sử dụng nhiều dissolve và fade. Thách thức chính là **gradual transition** phức tạp khiến ranh giới giữa hai shot không sắc nét như chuyển cảnh đột ngột.

4.2.2 Bộ dữ liệu ClipShots

ClipShots [18] là bộ dữ liệu quy mô lớn từ YouTube và Weibo, gồm 4.039 video (TB 237 giây), 128.000+ chuyển cảnh đột ngột và 38.000+ chuyển cảnh dần được dán nhãn thủ công (shot TB 15.34 giây). Nội dung đa dạng (20+ danh mục) từ nghiệp dư đến chuyên nghiệp. Thách thức: thay đổi ánh sáng đột ngột, camera rung, hiệu ứng chuyển cảnh không quy ước (glitch, flash, zoom nhanh) và khoảng cách miền dữ liệu lớn.

4.2.3 So sánh tổng hợp các bộ dữ liệu

Bảng 4.1 tổng hợp các đặc điểm chính của ba bộ dữ liệu được sử dụng trong đánh giá hiệu năng các mô hình SBD.

Đặc điểm	BBC	ClipShots	SHOT
Loại nội dung	Phim tài liệu	Đa dạng	Video ngắn
Số lượng video	11	4,039	853
Độ dài TB video (s)	2,945	237	39.5
Độ dài TB shot (s)	6.57	15.34	2.59
Hard cuts	Nhiều	128,000+	8,890
Gradual transitions	Rất nhiều	38,000+	2,716
Độ khó	Trung bình	Cao	Rất cao
Thách thức chính	Gradual transitions	Đa dạng hiệu ứng	Nhịp độ nhanh

Bảng 4.1: So sánh chi tiết các bộ dữ liệu đánh giá SBD

Mỗi bộ dữ liệu đại diện cho một khía cạnh khác nhau của bài toán SBD trong thực tế:

- **BBC Planet Earth:** Đánh giá khả năng xử lý chuyển cảnh dần dần trong nội dung chuyên nghiệp.
- **ClipShots:** Đánh giá khả năng tổng quát hóa trên nội dung thế giới mở đa dạng.
- **SHOT:** Đánh giá hiệu năng trên video ngắn với nhịp độ nhanh và hiệu ứng phức tạp.

4.3 Các chỉ số đánh giá hiệu quả mô hình

Do dữ liệu SBD mất cân bằng nghiêm trọng (khung hình không chuyển cảnh chiếm đa số), khóa luận dùng bộ ba chỉ số Precision, Recall và F1-score thay cho Độ chính xác. Ký hiệu: N_c (TP), N_m (FN), N_f (FP) lần lượt là số ranh giới phát hiện đúng, bỏ sót, và báo động giả. Ngưỡng θ chuyển xác suất đầu ra thành quyết định nhị phân: dự đoán $> \theta$ được coi là ranh giới.

$$\text{Precision} = \frac{N_c}{N_c + N_f}, \quad (4.1)$$

$$\text{Recall} = \frac{N_c}{N_c + N_m}, \quad (4.2)$$

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4.3)$$

Precision cao đồng nghĩa ít báo động giả; Recall cao đồng nghĩa ít bỏ sót ranh giới. F1 là trung bình điều hòa của hai chỉ số, được dùng làm tiêu chí so sánh chính giữa các phương pháp vì nó phản ánh đồng thời cả hai chiều. Việc đánh giá trên nhiều bộ dữ liệu (SHOT, ClipShots, BBC) là cần thiết để kiểm tra khả năng tổng quát hóa.

4.4 Kịch bản thực nghiệm

Các kết quả trong khóa luận được tổ chức theo bốn nhóm: kết quả chính trên SHOT, đánh giá bổ sung trên BBC và ClipShots, so sánh Precision/Recall/F1, và các bảng kết quả bổ sung để giải thích xu hướng quan sát được. Phần thảo luận về lỗi và khả năng tổng quát hóa được chuyển sang Chương 5.

4.5 Tổng quan các nhóm thực nghiệm

Trước khi đi vào từng bảng chi tiết, Bảng 4.2 tóm tắt các nhóm thực nghiệm chính được sử dụng trong chương này. Bảng chỉ báo cáo F1-score đại diện để người đọc nắm toàn cảnh. Các chỉ số Precision, Recall và phân tích chi tiết được trình bày ở các mục sau. Bảng đầy đủ tất cả thí nghiệm được đặt tại Bảng B.3 trong Phụ lục B.

Nhóm thực nghiệm	SHOT	BBC	ClipShots	Ghi chú
Cấu hình cân bằng / triển khai	0.8545	0.9656	0.7530	AutoShotV2 với ngưỡng chung 0.10.
Ablation Pha 2 tốt nhất (B4)	0.8540	0.9570	0.7441	Temperature + Gaussian, không cần huấn luyện lại.
Hiệu chỉnh hậu xử lý CV	0.8540	0.9631	0.7881	A1 tốt nhất trên SHOT/BBC, A0 tốt nhất trên ClipShots.
Fine-tune toàn model + EMA	0.8417	0.9604	0.7860	EMA tốt hơn no-EMA nhưng không thay thế pipeline deploy.

Bảng 4.2: Tổng quan các nhóm thực nghiệm chính. Các giá trị là F1-score; mỗi dòng dùng protocol riêng nên chỉ dùng để định hướng, không so sánh trực tiếp ngoài phạm vi ghi chú.

4.6 Kết quả chính trên ba bộ dữ liệu

Bảng 4.3 tổng hợp F1-score của AutoShot, TransNetV2 và các biến thể AutoShotV1/AutoShotV2 khi đánh giá trên ba tập dữ liệu SHOT, BBC và ClipShots. Riêng AutoShotV2 trong bảng này được hiểu là kết quả chính dùng cùng một chính sách đánh giá cho cả ba bộ dữ liệu. Các giá trị tốt nhất khi cho phép chọn ngưỡng riêng theo từng bộ dữ liệu được trình bày ở Mục 4.8.

Phương pháp	SHOT	BBC	ClipShots
AutoShot theo báo cáo	0.8410	0.9710	0.7870
AutoShot tự chạy lại	0.8405	0.9554	0.7753
TransNetV2	0.7993	0.9620	0.7760
TransNetV2 tự chạy lại	chưa chạy	0.9593	0.7454
AutoShotV1	0.8480	0.9510	0.7987
AutoShotV2	0.8545	0.9656	0.7530

Bảng 4.3: So sánh F1-score của các mô hình trên SHOT, BBC và ClipShots. Hàng “AutoShot theo báo cáo” lấy từ bài báo gốc [23]; các hàng “tự chạy lại” là kết quả tái lập trong khóa luận với điểm lưu trọng số công khai và quy trình đánh giá thống nhất. Số đậm là kết quả tốt nhất theo cột trong thiết lập chính.

Sai lệch giữa “AutoShot theo báo cáo” và “tự chạy lại” (lên đến 1.56 điểm trên BBC) phản ánh biến động môi trường thường gặp khi tái lập kết quả (phiên bản thư viện, giá trị hạt giống, điểm lưu trọng số và ngưỡng quyết định - ngưỡng quyết định).

Nhận xét từ kết quả:

- Biến thể **AutoShotV1** cải thiện nhẹ trên SHOT (+0.75 điểm phần trăm) và tăng trên ClipShots so với cả AutoShot theo báo cáo gốc (+1.17 điểm phần trăm) lẫn AutoShot tự chạy lại (+2.34 điểm phần trăm), nhưng giảm nhẹ trên BBC. Theo ghi chú thực nghiệm, nếu loại ảnh hưởng từ một video bất thường thì F1 trên BBC có thể đạt khoảng 0.961.
- **AutoShotV2** cho kết quả tốt nhất trên SHOT (0.8545) và BBC (0.9656, vượt cả TransNetV2 lẫn AutoShot tự chạy lại) trong cấu hình cân bằng. Trên ClipShots, AutoShotV2 đạt 0.7530 – thấp hơn

AutoShot theo báo cáo gốc 3.4 điểm phần trăm và thấp hơn AutoShot tự chạy lại 2.2 điểm phần trăm, cho thấy một cấu hình triển khai chung chưa chuyển dịch hoàn toàn sang miền dữ liệu đa dạng hơn.

Bảng tổng hợp bổ sung cho SHOT và ClipShots được trình bày tại Phụ lục B.

4.7 So sánh Precision, Recall và F1-score

Bảng 4.4 trình bày chi tiết Precision, Recall và F1 của AutoShotV2 trên từng bộ dữ liệu, kèm theo số liệu TP/FP/FN tuyệt đối để làm rõ hành vi của mô hình. Bảng này dùng cùng một ngưỡng cho SHOT, BBC và ClipShots để đại diện cho cấu hình cân bằng; các kết quả tốt nhất riêng từng bộ dữ liệu được tách sang Mục 4.8.

Bảng 4.4: Precision, Recall, F1 của AutoShotV2 trên ba bộ dữ liệu theo cấu hình cân bằng/triển khai chính. Cả SHOT, BBC và ClipShots đều dùng ngưỡng triển khai $\theta = 0.10$.

Bộ dữ liệu (Dataset)	Ngưỡng	Precision	Recall	F1	TP / FP / FN
SHOT	0.10	0.8557	0.8533	0.8545	2147 / 362 / 369
ClipShots	0.10	0.6662	0.8659	0.7530	6242 / 3128 / 967
BBC	0.10	0.9750	0.9564	0.9656	4633 / 119 / 211

4.8 Kết quả tốt nhất theo từng bộ dữ liệu

Bên cạnh kết quả cân bằng ở Bảng 4.3 và Bảng 4.4, khóa luận tách riêng một mục để báo cáo giá trị tốt nhất theo từng bộ dữ liệu. Cách đọc mục này là: mỗi dataset (SHOT, ClipShots và BBC) được phép chọn ngưỡng quyết định tốt nhất riêng, nhằm xem giới hạn cải thiện theo từng miền dữ liệu. Các kết quả trong mục này không thay thế cấu hình chính, vì cấu hình chính ưu tiên một chính sách đánh giá ổn định và cân bằng hơn trên cả ba dataset.

Bảng 4.5: Đỉnh F1 khi chọn ngưỡng quyết định tốt nhất riêng cho từng bộ dữ liệu. Cột F1 cân bằng lấy từ cấu hình chính ở Bảng 4.4; cột cuối cho biết mức thay đổi khi chuyển sang kết quả tốt nhất theo từng dataset.

Dataset	Ngưỡng best	Precision	Recall	F1 tốt nhất	F1 cân bằng	Chênh lệch
SHOT	0.12	0.8408	0.8816	0.8607	0.8545	+0.0062
ClipShots	0.19	0.7011	0.8554	0.7706	0.7530	+0.0176
BBC	0.12	0.9668	0.9628	0.9648	0.9656	-0.0008

Bảng 4.5 cho thấy lựa chọn riêng theo từng dataset tạo ra đỉnh tốt hơn trên SHOT và ClipShots: SHOT tăng từ 0.8545 lên 0.8607, còn ClipShots tăng từ 0.7530 lên 0.7706. Tuy nhiên, BBC giảm nhẹ từ 0.9656 xuống 0.9648. Vì vậy, kết quả theo từng dataset cho thấy tiềm năng cải thiện cục bộ, còn kết quả chính của khóa luận vẫn là cấu hình cân bằng ở Mục 4.6.

4.9 Kết quả bổ sung theo biến thể

Bảng 4.6 và Bảng 4.7 báo cáo thêm các biến thể bổ sung để giải thích xu hướng kết quả. Các bảng này không thay thế kết quả chính ở Mục 4.6; chúng chỉ cho biết F1 thay đổi thế nào khi điều kiện thực nghiệm thay đổi.

Bảng 4.6: Kết quả bổ sung theo biến thể mô hình trên SHOT, BBC và ClipShots. A0 là AutoShot gốc, A1 là mốc kiểm soát, và các dòng còn lại là các biến thể được đo trong cùng nhóm thí nghiệm. Số đậm đánh dấu cấu hình được chọn cho kết quả chính, không nhất thiết là giá trị lớn nhất theo từng cột.

Cấu hình	SHOT	BBC	ClipShots
A0 – AutoShot gốc	0.8405	0.9554	0.7649
A1 – BCE + one-hot	0.8378	0.9570	0.6983
A2 – Focal only	0.8378	0.9567	0.6967
A3 – Many-hot only	0.8375	0.9563	0.7005
P1 – Gaussian only	0.8432	0.9436	0.7519
P2 – Temperature only	0.8378	0.9570	0.6983
B1 – Focal + many-hot	0.8384	0.9559	0.7006
B4 – Temperature + Gaussian	0.8540	0.9570	0.7441
B5 – Full candidate no-EMA	0.8542	0.9551	0.7409


Trong nhóm kết quả này, B4 là biến thể cân bằng nhất: F1 tăng rõ so với mốc A1 trên SHOT (+1.6 điểm phần trăm) và ClipShots (+4.6 điểm phần trăm), trong khi BBC gần như không đổi. Một số biến thể khác tăng mạnh trên một bộ dữ liệu nhưng làm giảm bộ dữ liệu còn lại, nên không phù hợp làm kết quả chính.

Bảng 4.7: Kết quả bổ sung với EMA trên SHOT, BBC và ClipShots. Bảng này dùng để quan sát xu hướng F1 của một nhóm thí nghiệm riêng; số đậm là giá trị tốt nhất theo cột.

Cấu hình	SHOT	BBC	ClipShots
A – Phase 1 raw	0.8412	0.9554	0.7648
B – Phase 1 + Gaussian	0.8477	0.9515	0.7899
D-noEMA control	0.8371	0.9494	0.7638
D-EMA, alpha=0.999	0.8417	0.9604	0.7860

Nhận xét từ hai bảng bổ sung:

- **Biến thể B4 cho kết quả cân bằng nhất.** F1 tăng trên SHOT và ClipShots nhưng không làm BBC giảm đáng kể, nên phù hợp hơn các biến thể chỉ tốt trên một miền dữ liệu.
- **EMA là kết quả bổ trợ.** So với mốc không EMA, EMA cho F1 cao hơn trên cả ba bộ (+0.0046 trên SHOT, +0.0110 trên BBC, +0.0222 trên ClipShots) và đạt F1 cao nhất trên BBC. Tuy nhiên kết quả này thuộc một nhóm thí nghiệm riêng, nên không được dùng thay cho kết quả chính.
- **ClipShots vẫn là điểm yếu chung.** Các biến thể bổ sung chưa vượt được baseline gốc một cách ổn định trên ClipShots, củng cố nhận định về hạn chế tổng quát hóa sang miền này.



Hình 4.3: So sánh F1 giữa các mô hình trên tập SHOT (200 video kiểm tra). AutoShotV2 đạt $F1 = 0.8545$, cải thiện +1.4 điểm phần trăm so với AutoShot gốc và +5.5 điểm phần trăm so với TransNetV2 mô hình cơ sở.

4.10 Kết quả kiểm định chéo theo từng bộ dữ liệu

Để củng cố nhận định về khoảng cách trên ClipShots một cách định lượng và tránh hiện tượng chọn kết quả trực tiếp trên tập kiểm tra, khóa

luận bổ sung kiểm định chéo 5 phần (5-fold cross-validation). F1 được đo trên phần giữ lại ở mỗi fold, nên bảng này cho biết xu hướng kết quả ổn định hơn khi xét riêng từng bộ dữ liệu.

Bảng 4.8: F1 kiểm định chéo 5 phần theo từng bộ dữ liệu. Số đậm là giá trị tốt nhất theo cột.

Mô hình	SHOT	BBC	ClipShots
A0 – AutoShot baseline	0.8443	0.9538	0.7881
A1 – Phase2 control	0.8540	0.9631	0.7575
B5 – Phase2 đầy đủ	0.8539	0.9584	0.7555

Ba kết luận chính:

- **Baseline A0 tăng rõ trên ClipShots.** F1 tăng từ 0.7649 lên 0.7881, cho thấy ClipShots nhạy với cách chọn ngưỡng và miền dữ liệu.
- **Pha 2 giúp SHOT và BBC nhưng vẫn kém A0 trên ClipShots.** Pha 2 vượt A0 trên SHOT (0.854 so với 0.844) và BBC (0.963 so với 0.954), nhưng vẫn thua trên ClipShots (0.757 so với 0.788).
- **Khoảng chênh lệch quan nhỏ.** Mức trần khi chọn trực tiếp trên tập kiểm tra rất sát với số kiểm định chéo (ví dụ ClipShots A0: 0.7896 so với 0.7881), cho thấy xu hướng kết quả ổn định.

4.11 Tổng kết chương

Chương này đã trình bày các bộ dữ liệu được sử dụng, đặc điểm chính của SHOT và hai bộ dữ liệu đánh giá bổ sung BBC, ClipShots, cùng bộ chỉ số Precision/Recall/F1. Trên cơ sở đó, chương báo cáo kết quả đánh giá AutoShotV2 trên từng bộ dữ liệu, so sánh với các mô hình tham chiếu và phân tích xu hướng Precision/Recall/F1. Những nội dung thảo luận sâu về lỗi còn tồn tại và khả năng tổng quát hóa được đặt ở Chương 5.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chương cuối thảo luận các lỗi còn tồn tại và khả năng tổng quát hóa sau thực nghiệm, sau đó tổng kết những đóng góp chính của khóa luận thông qua việc trả lời lần lượt ba câu hỏi nghiên cứu được đặt ra ở Chương 1, phân tích bốn nhóm hạn chế còn tồn tại, và đề xuất sáu hướng phát triển khả thi trong tương lai. Phần cuối cùng là lời kết về vai trò của các mô hình học sâu được tối ưu hóa bằng NAS trong việc giải quyết bài toán phát hiện ranh giới cảnh quay trên các nền tảng video ngắn hiện đại.

5.1 Thảo luận kết quả thực nghiệm

5.1.1 Breakdown theo bộ dữ liệu

Kết quả cho thấy SHOT là tập dữ liệu mà AutoShotV2 đạt F1 cao nhất, trong khi ClipShots suy giảm đáng kể. Xu hướng này nhất quán với đặc điểm dữ liệu đã mô tả ở Chương 4: SHOT có nhịp cảnh nhanh và phân phối gần với dữ liệu dùng để tinh chỉnh tầng phân loại, còn ClipShots có miền nội dung đa dạng hơn, nhiều hiệu ứng chuyển cảnh “hoang dã” và điều kiện ghi hình không đồng nhất.

Với BBC, mô hình giữ mức F1 cao nhưng không còn vượt trội khi so với cấu hình gốc. Điều này gợi ý rằng các kỹ thuật hậu xử lý đang ưu tiên phân phối của video ngắn nhiều hơn là phân phối video tài liệu dài.

5.1.2 Giải thích suy giảm trên ClipShots

Bảng 5.1 phân tách F1 của AutoShotV2 trên ClipShots theo loại chuyển cảnh, làm rõ nguyên nhân suy giảm. Bảng này dùng cùng ngưỡng triển khai 0.10 với kết quả chính ở Bảng 4.4; các ngưỡng tốt nhất riêng theo từng bộ dữ liệu được trình bày tách biệt trong Mục 4.8.

Bảng 5.1: Breakdown Precision/Recall/F1 theo loại chuyển cảnh trên ClipShots test (500 video, ngưỡng = 0.10).

Loại chuyển cảnh	Precision	Recall	F1
Cut (chuyển cảnh đột ngột)	0.5826	0.8860	0.7030
Gradual (chuyển cảnh dần)	0.6456	0.0442	0.0828
Tổng	0.7477	0.7897	0.7681

Độ bao phủ của loại *gradual* (độ bao phủ chuyển cảnh dần) chỉ đạt 4.42% – mô hình gần như không phát hiện được các chuyển cảnh dần trên ClipShots. Đây là nguyên nhân chính kéo F1 tổng thể xuống thấp hơn so với SHOT.

Mức giảm 3.4 điểm phần trăm so với AutoShot theo báo cáo gốc trên ClipShots, kết hợp với độ bao phủ ranh giới dần (độ bao phủ chuyển cảnh dần) cực thấp ở Bảng 5.1, gợi mở ba giả thuyết kỹ thuật cần kiểm chứng thêm:

1. **Many-hot ± 1 frame có thể chưa phù hợp với chuyển cảnh đột ngột sắc của ClipShots:** Khi phần lớn ranh giới ClipShots là chuyển cảnh đột ngột rất sắc, việc mở rộng nhãn dương ra ± 1 frame có thể làm “dày” vùng dương hơn mức cần thiết và làm mềm độ sắc quyết định biên — một hiệu ứng mà many-hot không gây ra trên SHOT vì SHOT có tỉ lệ chuyển cảnh dần (chuyển cảnh dần) cao hơn.
2. **Hiệu chỉnh nhiệt độ (Temperature scaling) tối ưu trên validation SHOT có thể không tổng quát hóa sang miền khác:** $T^* = 0.3878$ được tìm trên tập xác thực của SHOT; khi phân phối logit của mô hình trên ClipShots khác đi, cùng một hệ số có thể làm phân phối xác suất bị lệch và đẩy ngưỡng tối ưu sang vùng không ổn định.
3. **Cấu hình Focal Loss có thể thiên về phân phối nhãn của SHOT:** Bộ $\gamma = 1.0, \alpha = 0.5$ được chọn qua tìm kiếm lưới trên SHOT; do tỉ lệ chuyển cảnh và độ khó mẫu trên ClipShots khác, cấu hình này chưa chắc là tối ưu cho miền đa dạng hơn.

Cả ba giả thuyết trên đều cần thí nghiệm đối chứng tách biệt từng yếu

tổ (ví dụ: chạy lại AutoShotV2 không many-hot, hoặc dùng T^* tính lại trên tập xác thực của ClipShots) để loại trừ các nhân tố khác.

5.1.3 Giới hạn của phân tích hiện tại

Các giả thuyết trên được xây dựng từ số liệu F1/Precision/Recall hiện có, chưa đi kèm thí nghiệm đối chứng tách biệt từng yếu tố. Do không chạy lại toàn bộ ma trận thử nghiệm phân rã trên mọi tập dữ liệu trong phạm vi khóa luận, kết luận ở đây nên được xem là định hướng phân tích có cơ sở, và cần kiểm chứng thêm trong công việc tương lai.

5.1.4 Phát hiện bổ sung ngoài phạm vi câu hỏi nghiên cứu

Bên cạnh ba câu hỏi nghiên cứu chính, thí nghiệm còn cho thấy một số quan sát đáng chú ý ở tầng phương pháp luận và triển khai:

- **SHOT là phép thử khó nhưng sát thực tế video ngắn.** So với BBC và ClipShots, SHOT có shot ngắn hơn (TB 2.59 s) và nhiều hiệu ứng chuyển cảnh phức tạp hơn; do đó là chuẩn đánh giá phù hợp hơn cho môi trường TikTok/Reels/Shorts so với các chuẩn đánh giá video dài truyền thống.
- **NAS đắt nhưng có thể tái sử dụng.** Chi phí tìm kiếm kiến trúc và huấn luyện lại với KD/Weight Grafting đáng kể, nhưng AutoShotV2 cho thấy mạng xương sống đã tìm được có thể dùng lại nhiều lần cho các cải tiến ở tầng phân loại với chi phí phụ trội rất nhỏ — một mô hình triển khai khả thi cho phòng lab có tài nguyên hạn chế.
- **Ngưỡng suy luận là tham số ứng dụng, không phải tham số mô hình.** Ngưỡng tối ưu theo F1 cho cân bằng Precision–Recall tốt nhất; ngưỡng cao hơn ưu tiên Precision khi đánh đổi Recall. Lựa chọn ngưỡng nên căn cứ vào yêu cầu nghiệp vụ cuối (số lượng dương tính giả chấp nhận được trong workflow biên tập), không nhất thiết phải là một con số tuyệt đối.

5.2 Kết luận chung

Khóa luận đã hoàn thành các mục tiêu nghiên cứu đề ra, tập trung vào bài toán phát hiện ranh giới cảnh quay (Shot Boundary Detection – SBD) trong bối cảnh đặc thù của video ngắn. Phần này tổng kết kết quả nghiên cứu thông qua hai góc nhìn: trả lời trực tiếp ba câu hỏi nghiên cứu RQ1–RQ3 đã đặt ra ở Mục 1.6, sau đó tổng hợp ba nhóm đóng góp chính.

5.2.1 Trả lời các câu hỏi nghiên cứu

RQ1 – NAS có giúp cải thiện hiệu năng SBD trên video ngắn so với mạng xương sống cố định? Câu trả lời là **có**. Trên tập SHOT, AutoShot đạt $F1 = 0.8405$, vượt mô hình cơ sở TransNetV2 ($F1 = 0.7993$) khoảng +4.1 điểm phần trăm trên cùng tập kiểm tra và cùng giao thức đánh giá. Việc để NAS tự khám phá kiến trúc trong không gian 83.9 triệu cấu hình ứng viên (gồm bốn biến thể DDCNN: V2, A, B, C) đem lại lợi thế định lượng rõ rệt so với mạng xương sống cố định được thiết kế thủ công. Lợi thế này được giải thích bởi khả năng NAS thích nghi với phân phối dữ liệu mục tiêu – video ngắn có shot dày đặc và hiệu ứng kỹ xảo phức tạp – thay vì giả định một kiến trúc cố định hoạt động tốt cho mọi miền.

RQ2 – Các kỹ thuật ở tầng phân loại có cải thiện F1 mà không cần thay đổi mạng xương sống? Câu trả lời là **có**. Khi giữ nguyên mạng xương sống AutoShot và chỉ tinh chỉnh tầng phân loại bằng tổ hợp Focal Loss, nhân many-hot, Gaussian smoothing và temperature scaling, AutoShotV2 đạt $F1 = 0.8545$ trên SHOT – cao hơn AutoShot gốc +1.4 điểm phần trăm và cao hơn mô hình cơ sở TransNetV2 +5.5 điểm phần trăm. Phát hiện này cho thấy ngay cả khi NAS đã tối ưu kiến trúc, vẫn còn dư địa cải thiện đáng kể chỉ thông qua thiết kế lại tầng đầu ra và hậu xử lý xác suất. Mức cải thiện trên đạt được mà không cần huấn luyện mạng xương sống từ đầu, qua đó tách biệt tác động của nhóm kỹ thuật ở tầng phân loại so với phần mạng xương sống.

RQ3 – Mức cải thiện trên SHOT có duy trì khi đánh giá chéo trên BBC và ClipShots? Câu trả lời là **một phần**. Trên BBC,

AutoShotV2 đạt $F1 = 0.9656$, vượt TransNetV2 (0.9620) và AutoShot tự chạy lại (0.9554), cho thấy các kỹ thuật hiệu chỉnh xác suất có thể chuyển dịch tốt sang miền video tài liệu trong thiết lập hiện tại. Tuy nhiên, trên ClipShots, $F1$ của AutoShotV2 đạt 0.7530, thấp hơn AutoShot theo báo cáo gốc (0.7870) và AutoShot tự chạy lại (0.7753). Hiện tượng *domain-specific overfitting* này được lý giải bởi ba giả thuyết kỹ thuật trong Chương 4: nhãn many-hot mở rộng ± 1 frame chưa phù hợp với phân phối chuyển cảnh của ClipShots, hiệu chỉnh nhiệt độ tối ưu trên tập xác thực của SHOT bị lệch khi áp dụng sang miền khác, và cấu hình Focal Loss ($\gamma = 1.0, \alpha = 0.5$) thiên về phân phối nhãn của SHOT. Như vậy, RQ3 chỉ ra một giới hạn quan trọng: tối ưu cho một miền cụ thể không tự động chuyển dịch ổn định sang mọi miền khác – đây là động lực cho Mục 5.5 về xuyên miền calibration.

5.3 Đóng góp của khóa luận

Trên cơ sở ba câu trả lời ở trên, khóa luận đem lại ba nhóm đóng góp chính:

1. **Hệ thống hóa tri thức (nền cho RQ1):** Cung cấp khảo sát có cấu trúc về dòng chảy nghiên cứu SBD, từ phương pháp cổ điển dựa trên đặc trưng thủ công, đến các kiến trúc học sâu CNN/3D ConvNet/Transformer, và gần đây nhất là hướng NAS. Phân tích định lượng trên ba bộ dữ liệu chuẩn (SHOT, BBC, ClipShots) làm rõ khoảng trống nghiên cứu giữa video dài truyền thống và video ngắn hiện đại. Cơ sở khảo sát này định vị câu trả lời cho RQ1 trong bối cảnh các mạng xương sống học sâu hiện hành.
2. **Đóng góp về phương pháp (giải quyết RQ2):** Phân tích và triển khai quy trình AutoShot/AutoShotV2, trong đó bổ sung nhóm kỹ thuật cải tiến ở tầng phân loại và hậu xử lý (Focal Loss, nhãn many-hot, hiệu chỉnh nhiệt độ, làm mượt Gaussian) mà không thay đổi mạng xương sống gốc — cô lập đóng góp của tầng phân loại và đem lại cải thiện thực chất chỉ thông qua thiết kế tầng đầu ra.

3. **Đóng góp về kết quả thực nghiệm (đối với RQ3):** Trên tập SHOT, AutoShotV2 đạt $F1 = 0.8545$, cao hơn AutoShot gốc khoảng +1.4 điểm phần trăm và cao hơn mô hình cơ sở TransNetV2 khoảng +5.5 điểm phần trăm; đồng thời cung cấp phân tích so sánh chéo trên BBC và ClipShots làm rõ mức độ tổng quát hóa — vượt mô hình cơ sở trên BBC nhưng suy giảm trên ClipShots, chỉ ra giới hạn xuyên miền cần khắc phục trong nghiên cứu tiếp theo.

Tóm lại, khóa luận khẳng định rằng việc kết hợp giữa *kiến trúc mạng xương sống linh hoạt* được tối ưu bởi NAS và *quy trình huấn luyện-hậu xử lý chặt chẽ* ở tầng phân loại là chìa khóa để đạt hiệu suất cao trên các nền tảng nội dung video ngắn có nhịp độ nhanh.

5.4 Hạn chế của nghiên cứu

Mặc dù đạt được những kết quả tích cực, khóa luận vẫn tồn tại bốn nhóm hạn chế cần được nêu rõ:

5.4.1 Chi phí tính toán của giai đoạn NAS

Quy trình NAS hai giai đoạn của AutoShot (huấn luyện SuperNet + tìm kiếm bằng Bayesian Optimization) cộng với chưng cất tri thức và Weight Grafting có chi phí tổng cộng khoảng 76–91 giờ trên hệ thống đa GPU V100. Đây là một *thách thức triển khai* hơn là lỗi hồng phương pháp luận: trong phạm vi khóa luận, nhóm thực hiện đã tận dụng các điểm lưu trọng số (điểm lưu trọng số) công khai của AutoShot gốc [23] thay vì tự chạy lại quy trình tìm kiếm, cho phép tập trung tài nguyên vào các cải tiến ở tầng phân loại. Tuy giải pháp này hợp lý cho khóa luận, nó kế thừa giả thiết rằng kiến trúc tìm được trên SHOT (theo tác giả gốc) cũng là điểm khởi đầu phù hợp cho miền video ngắn nói chung — giả thiết này chưa được kiểm chứng độc lập trong khóa luận và là một giới hạn cần lưu ý khi mở rộng sang các phân phối video ngắn khác.

5.4.2 Nhảy cảm với chuyển động cực nhanh và hiệu ứng ánh sáng

Trong một số trường hợp video ngắn có chuyển động máy quay cực nhanh hoặc hiệu ứng đèn flash mạnh, mô hình AutoShotV2 vẫn xảy ra báo động giả (dương tính giả) do nhầm lẫn giữa biến đổi trong nội bộ shot và chuyển cảnh thật. Đặc biệt, các video game/animation với hiệu ứng kỹ xảo dày đặc tạo ra biến thiên thị giác lớn nhưng không tương ứng với chuyển cảnh thật – một loại nhiễu cấu trúc khó xử lý chỉ bằng tín hiệu thị giác đơn lẻ.

5.4.3 Mất cân bằng dữ liệu chưa được giải quyết triệt để

Mặc dù đã áp dụng Focal Loss và nhãn many-hot, sự chênh lệch giữa số khung hình nền (không phải ranh giới) và khung hình ranh giới vẫn rất lớn (xấp xỉ 1:100 đến 1:200 tùy bộ dữ liệu). Hậu quả là mô hình đôi khi bị thiên về Precision cao nhưng Recall thấp ở các chuyển cảnh dần (chuyển cảnh dần) khó. Việc tự động tinh chỉnh tham số γ, α của Focal Loss theo phân phối nhãn của từng tập dữ liệu cụ thể là một hướng cải thiện nhưng chưa được khảo sát đầy đủ trong khóa luận.

5.4.4 Khoảng cách miền dữ liệu giữa SHOT và các bộ dữ liệu khác

Như đã chỉ ra ở RQ3, các kỹ thuật trong AutoShotV2 tối ưu cho phân phối của SHOT có biểu hiện suy giảm khoảng 3.1 điểm phần trăm trên ClipShots. Khóa luận đã đề xuất ba giả thuyết kỹ thuật giải thích hiện tượng (nhãn many-hot, hiệu chỉnh nhiệt độ tối ưu trên SHOT, cấu hình Focal Loss) nhưng chưa có thử nghiệm phân rã (thử nghiệm phân rã) tách biệt từng yếu tố trên ClipShots — do đó các kết luận về xuyên miền hiện ở mức định hướng phân tích thay vì khẳng định nguyên nhân. Khả năng tổng quát hóa sang dữ liệu sản xuất nội dung tiếng Việt cũng chưa được kiểm chứng và sẽ được thảo luận ở Mục 5.5.

5.5 Hướng phát triển tương lai

Trên cơ sở những phát hiện và hạn chế đã phân tích, sáu hướng phát triển khả thi được đề xuất:

5.5.1 Tối ưu hóa real-time và triển khai trên thiết bị

Nghiên cứu các kỹ thuật nén mô hình (cắt tỉa, lượng tử hóa int8/int4, chưng cất tri thức sang mô hình học trò nhỏ) để đưa AutoShotV2 vào các ứng dụng xử lý video trực tiếp với độ trễ thấp. Mục tiêu cụ thể là đạt thông lượng tối thiểu 30 FPS trên các thiết bị di động phổ thông, mở đường cho ứng dụng SBD trên thiết bị cho các nền tảng video ngắn.

5.5.2 Phát hiện đa phương thức (Multimodal SBD)

Kết hợp tín hiệu âm thanh (tín hiệu âm thanh như sự thay đổi đột ngột của track nhạc nền) và thông tin trong miền nén (vector chuyển động của bộ mã hóa-giải mã H.264/H.265) để tăng cường độ bền vững khi tín hiệu thị giác bị nhiễu hoặc mờ nhòe. Đặc biệt, đối với video game, tín hiệu âm thanh thường ổn định hơn hình ảnh và có thể hỗ trợ tốt cho việc loại trừ các biến đổi nội bộ shot do kỹ xảo gây ra.

5.5.3 Khả năng tổng quát hóa xuyên miền

Xây dựng cơ chế thích nghi miền (Domain Adaptation) để mô hình hoạt động ổn định trên nhiều nền tảng khác nhau (TikTok, YouTube Shorts, phim điện ảnh truyền thống) mà không cần huấn luyện lại từ đầu. Bám sát ba giả thuyết xuyên miền đã nêu ở Chương 4, các hướng cụ thể gồm: (i) *hiệu chỉnh nhiệt độ tại thời điểm suy diễn (test-time temperature recalibration)* — tính lại T^* trên một tập xác thực nhỏ của miền đích trước khi suy diễn để khắc phục lệch logit; (ii) *meta-learning cho các tham số Focal Loss* — học một phân phối khởi tạo γ, α thích nghi nhanh khi gặp miền mới, dựa trên thống kê phân phối nhãn; và (iii) *domain-adversarial training* cho tầng phân loại để học biểu diễn đầu ra ít phụ thuộc vào miền nguồn. Ba hướng này cho phép giữ nguyên mạng xương sống đã được tối ưu hóa bằng NAS mà vẫn chuyển dịch được sang miền mới với chi phí thấp.

5.5.4 Phân loại fine-grained loại chuyển cảnh

Mở rộng bài toán từ phân loại nhị phân (boundary/non-boundary) sang phân loại đa lớp với các nhãn cụ thể như Cut, Dissolve, Fade-in, Fade-out, Wipe. Việc này phục vụ cho các hệ thống biên tập video tự động cao cấp như tự động chú thích loại chuyển cảnh khi nhập video thô, hoặc gợi ý hiệu ứng tương tự cho người sáng tạo nội dung.

5.5.5 Tự giám sát và mở rộng dữ liệu

Khai thác các phương pháp học tự giám sát (contrastive learning, masked frame prediction) trên kho dữ liệu video chưa gán nhãn quy mô lớn để mô hình học được các biểu diễn đặc trưng mạnh hơn mà không phụ thuộc nhiều vào nhãn thủ công. Đây là hướng phù hợp với xu thế chung của học sâu trong thị giác máy tính và có thể giảm chi phí gán nhãn cho việc mở rộng dataset.

5.5.6 Mở rộng dataset cho video tiếng Việt

Xây dựng *SHOT-VN* – một bộ dữ liệu chuyên biệt cho video ngắn tiếng Việt thu thập từ TikTok Việt Nam, YouTube Shorts của các nhà sáng tạo nội dung Việt – với hệ thống chú thích theo cùng quy chuẩn của SHOT gốc. Bộ dữ liệu này sẽ cho phép đánh giá khả năng tổng quát hóa của các mô hình hiện hành sang văn hóa và phong cách dựng video đặc thù Việt Nam, đồng thời tạo điểm chuẩn cho các nghiên cứu SBD trong nước.

5.6 Lời kết

Bài toán phát hiện ranh giới cảnh quay tưởng chừng là một bước tiền xử lý đơn giản, nhưng khi đặt trong bối cảnh video ngắn hiện đại với nhịp cắt cảnh dày đặc, hiệu ứng kỹ xảo phức tạp và sự đa dạng cao của nội dung, nó lại trở thành một bài toán có nhiều thách thức kỹ thuật và ý nghĩa thực tiễn. Khóa luận đã đóng góp một bước tiến nhỏ trên hành trình giải quyết bài toán này: từ việc hệ thống hóa khảo sát, đến đề xuất AutoShotV2 với $F1 = 0.8545$ trên SHOT, và quan trọng không kém – chỉ ra rõ những giới hạn cần khắc phục về khả năng tổng quát hóa đa miền.

Trong thời đại video ngắn tiếp tục bùng nổ trên các nền tảng số, các hệ thống phân tích video tự động chính xác và hiệu quả sẽ là nền tảng cho nhiều ứng dụng giá trị – từ kiểm duyệt nội dung, gợi ý cá nhân hóa, đến công cụ biên tập sáng tạo. Khóa luận này chỉ ra rõ giới hạn của khả năng tổng quát hóa đa miền trong các phương pháp SBD hiện hành và mở đường cho hai hướng nghiên cứu cụ thể: (i) cơ chế hiệu chỉnh xác suất thích nghi theo miền đích thay vì cố định theo miền nguồn, và (ii) xây dựng bộ dữ liệu SHOT-VN cho video ngắn tiếng Việt làm bộ phóng cho các nghiên cứu SBD trong nước. Nhóm thực hiện hy vọng các phân tích và quy trình AutoShotV2 sẽ là điểm tham chiếu hữu ích cho các công trình tiếp theo của cộng đồng học thuật trong và ngoài nước.

Danh mục công trình của tác giả

Trong phạm vi thực hiện hiện tại, nhóm tác giả chưa có công trình công bố chính thức liên quan trực tiếp đến khóa luận này. Các kết quả và phân tích trong báo cáo là cơ sở để tiếp tục hoàn thiện theo hướng bài báo khoa học hoặc báo cáo hội nghị trong giai đoạn tiếp theo.

Tài liệu tham khảo

Tiếng Anh

- [1] Abdulhussain, Sadiq H. et al. “Methods and Challenges in Shot Boundary Detection: A Review”. In: *Entropy* 20.4 (2018), p. 214. DOI: 10.3390/e20040214. URL: <https://www.mdpi.com/1099-4300/20/4/214>.
- [2] Baraldi, Lorenzo, Grana, Costantino, and Cucchiara, Rita. “Shot and Scene Detection via Hierarchical Clustering for Re-using Broadcast Video”. In: *Computer Analysis of Images and Patterns* (2015). URL: https://link.springer.com/chapter/10.1007/978-3-319-23192-1_67.
- [3] Elsken, Thomas, Metzen, Jan Hendrik, and Hutter, Frank. “Neural Architecture Search: A Survey”. In: *arXiv preprint arXiv:1808.05377* (2018). Journal reference: Journal of Machine Learning Research 20 (2019) 1–21. URL: <https://arxiv.org/abs/1808.05377>.
- [4] Esteve, Adrián et al. “Shot Boundary Detection with 3D Depth-wise Convolutions and Visual Attention”. In: *Sensors* 23.12 (2023), p. 5620.
- [5] Guo, Chuan et al. “On Calibration of Modern Neural Networks”. In: *arXiv preprint arXiv:1706.04599* (2017). Published at ICML 2017. DOI: 10.48550/arXiv.1706.04599. URL: <https://arxiv.org/abs/1706.04599>.
- [6] Guo, Zichao et al. “Single Path One-Shot Neural Architecture Search with Uniform Sampling”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2020. URL: <https://arxiv.org/abs/1904.00420>.

- [7] Hassanien, Ahmed et al. “Large-scale, Fast and Accurate Shot Boundary Detection through Spatio-temporal Convolutional Neural Networks”. In: *arXiv preprint arXiv:1705.03281* (2017). URL: <https://arxiv.org/abs/1705.03281>.
- [8] Hinton, Geoffrey, Vinyals, Oriol, and Dean, Jeff. “Distilling the knowledge in a neural network”. In: *arXiv preprint arXiv:1503.02531* (2015). URL: <https://arxiv.org/abs/1503.02531>.
- [9] Kar, T. et al. “Video shot-boundary detection: issues, challenges and solutions”. In: *Artificial Intelligence Review* 57.104 (2024). Springer. DOI: 10.1007/s10462-024-10742-1. URL: <https://link.springer.com/article/10.1007/s10462-024-10742-1>.
- [10] Lin, Tsung-Yi et al. “Focal Loss for Dense Object Detection”. In: *arXiv preprint arXiv:1708.02002* (2017). Published at ICCV 2017. DOI: 10.48550/arXiv.1708.02002. URL: <https://arxiv.org/abs/1708.02002>.
- [11] Liu, Hanxiao, Simonyan, Karen, and Yang, Yiming. “DARTS: Differentiable Architecture Search”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2019. URL: <https://arxiv.org/abs/1806.09055>.
- [12] Loshchilov, Ilya and Hutter, Frank. “SGDR: Stochastic Gradient Descent with Warm Restarts”. In: *arXiv preprint arXiv:1608.03983* (2017). Published at ICLR 2017. DOI: 10.48550/arXiv.1608.03983. URL: <https://arxiv.org/abs/1608.03983>.
- [13] Müller, Rafael, Kornblith, Simon, and Hinton, Geoffrey E. “When Does Label Smoothing Help?” In: *arXiv preprint arXiv:1906.02629* (2019). Published at NeurIPS 2019. DOI: 10.48550/arXiv.1906.02629. URL: <https://arxiv.org/abs/1906.02629>.
- [14] Ren, Pengzhen et al. “A Comprehensive Survey of Neural Architecture Search: Challenges and Solutions”. In: *arXiv preprint arXiv:2006.02903* (2020). Accepted by ACM Computing Surveys 2021. URL: <https://arxiv.org/abs/2006.02903>.

- [15] Seridi, Hamid et al. “Shot Boundary Detection: Fundamental Concepts and Survey”. In: *CEUR Workshop Proceedings, Vol. 2589*. CEUR-WS.org. 2020. URL: <https://ceur-ws.org/Vol-2589/Paper6.pdf>.
- [16] Souček, Tomáš and Lokoč, Jakub. “TransNet V2: An effective deep network architecture for fast shot transition detection”. In: *arXiv preprint arXiv:2008.04838* (2020). URL: <https://arxiv.org/abs/2008.04838>.
- [17] Souček, Tomáš, Moravec, Jaroslav, and Lokoč, Jakub. “TransNet: A deep network for fast detection of common shot transitions”. In: *arXiv preprint arXiv:1906.03363* (2019). URL: <https://arxiv.org/abs/1906.03363>.
- [18] Tang, Shitao et al. “Fast Video Shot Transition Localization with Deep Structured Models”. In: *arXiv preprint arXiv:1808.04234* (2018). Introduces the ClipShots dataset. URL: <https://arxiv.org/abs/1808.04234>.
- [19] Tran, Du et al. “Learning Spatiotemporal Features with 3D Convolutional Networks”. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2015, pp. 4489–4497. DOI: 10.1109/ICCV.2015.510. URL: <https://arxiv.org/abs/1412.0767>.
- [20] Van Anh. *Short-form video trend harming youth*. VietnamNet Global; cites data from Sprout Social. May 7, 2023. URL: <https://vietnamnet.vn/en/short-form-video-trend-harming-youth-2140096.html> (visited on 05/16/2026).
- [21] Vaswani, Ashish et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017. URL: <https://arxiv.org/abs/1706.03762>.
- [22] White, Colin et al. “Neural Architecture Search: Insights from 1000 Papers”. In: *arXiv preprint arXiv:2301.08727* (2023). URL: <https://arxiv.org/abs/2301.08727>.

- [23] Zhu, Wentao et al. “AutoShot: A Short Video Dataset and State-of-the-Art Shot Boundary Detection”. In: *arXiv preprint arXiv:2304.06116* (2023). URL: <https://arxiv.org/abs/2304.06116>.

Chương A

Ký hiệu toán học và quy ước đánh giá

Phụ lục này tổng hợp các ký hiệu chính xuất hiện trong khóa luận và nhắc lại các quy ước đánh giá được sử dụng xuyên suốt phần thực nghiệm.

A.1 Ký hiệu sử dụng trong khóa luận

Ký hiệu	Tên gọi	Ý nghĩa
$V = \{f_1, \dots, f_n\}$	Chuỗi khung hình đầu vào	Video gồm n khung hình theo thứ tự thời gian.
f_i	Khung hình thứ i	Phần tử cơ bản của video đầu vào.
$B = \{b_1, \dots, b_m\}$	Tập ranh giới cảnh quay	Tập hợp các vị trí bắt đầu shot mới trong video.
b_j	Ranh giới thứ j	Một mốc thời gian biểu thị sự chuyển từ shot hiện tại sang shot kế tiếp.
$\hat{y}_{single}$	Dự đoán single-frame	Xác suất ranh giới tại khung hình trung tâm.
$\hat{y}_{all}$	Dự đoán all-frame / many-hot	Xác suất trên vùng lân cận quanh ranh giới, dùng để hỗ trợ huấn luyện.
$p[t]$	Xác suất tại thời điểm t	Giá trị đầu ra của mô hình trước hoặc sau hậu xử lý.
θ	Ngưỡng quyết định	Ngưỡng chuyển xác suất sang quyết định có ranh giới hay không (ngưỡng $> \theta \Rightarrow$ có ranh giới).
T^*	Nhiệt độ tối ưu	Hệ số hiệu chỉnh xác suất trong temperature scaling.
σ	Độ lệch chuẩn Gaussian	Tham số điều khiển mức làm mịn của Gaussian smoothing.
γ	Tham số tập trung	Tham số γ của Focal Loss, điều khiển mức ưu tiên mẫu khó.
α	Tham số cân bằng	Tham số α của Focal Loss, điều chỉnh tỉ lệ giữa lớp dương và âm.
β	Hệ số <i>momentum</i> EMA	Hệ số trung bình động mũ trên trọng số mô hình.
η_t	Tốc độ học tại bước t	Tốc độ học theo lịch trình Cosine với khởi động dần.
$\mathcal{A}$	Không gian tìm kiếm NAS	Tập hợp toàn bộ kiến trúc ứng viên trong bài toán NAS.
$\mathcal{L}$	Hàm mất mát tổng	Đại lượng tối ưu trong quá trình huấn luyện mô hình.

A.2 Quy ước đánh giá

Trong bài toán phát hiện ranh giới cảnh quay, dữ liệu thường mất cân bằng mạnh do số khung hình nền lớn hơn rất nhiều số khung hình thuộc ranh giới. Vì vậy, khóa luận không dùng Độ chính xác làm chỉ số chính mà ưu tiên bộ ba Precision, Recall và F1-score.

- **True Positive (TP):** mô hình dự đoán đúng một ranh giới cảnh quay.
- **False Positive (FP):** mô hình dự đoán có ranh giới nhưng thực tế không có.
- **False Negative (FN):** mô hình bỏ sót một ranh giới có thật trong dữ liệu gán nhãn.

Các chỉ số được tính theo các công thức:

$$Precision = \frac{TP}{TP + FP} \quad (A.1)$$

$$Recall = \frac{TP}{TP + FN} \quad (A.2)$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (A.3)$$

Trong các thí nghiệm của khóa luận, F1-score được dùng làm tiêu chí so sánh chính giữa các mô hình vì đây là chỉ số phản ánh tốt nhất sự cân bằng giữa khả năng phát hiện đúng và khả năng hạn chế báo động giả.

Chương B

Bảng tổng hợp kết quả bổ sung

Phụ lục này tổng hợp lại các kết quả F1 chính trên hai bộ dữ liệu được dùng để phân tích sâu trong Chương 4: SHOT và ClipShots. Các bảng chỉ giữ những số liệu đã được dùng trong phần thực nghiệm chính, tránh đưa vào các dòng chi tiết chưa có dữ liệu đối chiếu đầy đủ.

B.1 Bộ dữ liệu SHOT

Bảng B.1 nhắc lại kết quả trung bình của ba mô hình tiêu biểu trên tập kiểm tra SHOT.

Bảng B.1: Kết quả F1 trung bình trên tập kiểm tra của SHOT

Tập dữ liệu	TransNetV2	AutoShot	AutoShotV2
SHOT tập kiểm tra	0.7993	0.8405	0.8545

Ghi chú đọc bảng:

- Các giá trị trong bảng khớp với Bảng 4.3 trong Chương 4.
- AutoShotV2 đạt F1 cao nhất trên SHOT, phù hợp với mục tiêu tối ưu cho miền video ngắn.

B.2 Bộ dữ liệu ClipShots

Bảng B.2 tổng hợp kết quả F1 trên ClipShots. Đáng chú ý, ClipShots có miền nội dung đa dạng hơn SHOT, do đó được dùng để quan sát khả năng tổng quát hóa của các biến thể.

Bảng B.2: Kết quả F1 trung bình trên ClipShots

Tập dữ liệu	TransNetV2	AutoShot	AutoShotV2
ClipShots (theo báo cáo)	0.7760	0.7870	0.7530
ClipShots (tự chạy lại)	0.7454	0.7753	0.7530

Quan sát đáng chú ý. Mức suy giảm khoảng 3.1 điểm phần trăm của AutoShotV2 so với AutoShot theo báo cáo gốc trên ClipShots cho thấy cấu hình tối ưu cho SHOT chưa chuyển dịch ổn định sang miền dữ liệu đa dạng hơn. Phân tích sâu hơn (xem Chương 5, Mục 5.1) chỉ ra ba giả thuyết kỹ thuật chính:

1. Nhãn many-hot ± 1 frame chưa phù hợp với chuyển cảnh hard-cut sắc nét đặc trưng của ClipShots.
2. Hệ số temperature scaling T^* được tối ưu trên validation SHOT bị lệch khi áp dụng sang ClipShots.
3. Cấu hình Focal Loss ($\gamma = 1.0, \alpha = 0.5$) thiên về phân phối nhãn của SHOT.

Các bảng ở hai mục đầu của phụ lục này chỉ đóng vai trò tổng hợp lại số liệu đã dùng trong phần thực nghiệm chính trên SHOT và ClipShots. Việc kiểm chứng định lượng sâu hơn theo từng video cần được thực hiện khi có đầy đủ *log* hoặc CSV chi tiết cho từng mẫu kiểm tra.

B.3 Bảng đầy đủ tất cả thực nghiệm

Bảng B.3 tổng hợp tất cả các dòng thực nghiệm đã được sử dụng trong Chương 4 và phần thảo luận ở Chương 5. Các giá trị trong ba cột bộ dữ liệu là F1-score. Do các nhóm thí nghiệm dùng protocol khác nhau, bảng này dùng để tra cứu tổng quan; việc so sánh kết luận nên dựa trên từng nhóm riêng trong Chương 4.

Bảng B.3: Bảng đầy đủ tất cả thực nghiệm. Các giá trị SHOT, BBC và ClipShots là F1-score.

Nhóm	Thực nghiệm / protocol	SHOT	BBC	Clip-Shots	Ghi chú
Deploy checkpoint	Phase2 deploy checkpoint, deploy threshold	0.8545	0.9656	0.7530	T=0.3878, sigma=2.0, threshold=0.10.
Deploy checkpoint	Phase2 deploy checkpoint, best sweep	0.8545	0.9656	0.7557	ClipShots tốt nhất tại threshold 0.15; SHOT/BBC trùng deploy.
Ablation no-EMA	A0 – AutoShot gốc	0.8405	0.9554	0.7649	AutoShot gốc, best threshold từng dataset.
Ablation no-EMA	A1 – BCE + one-hot	0.8378	0.9570	0.6983	Control Phase2 tối giản.
Ablation no-EMA	A2 – Focal only	0.8378	0.9567	0.6967	Chỉ thêm Focal Loss.
Ablation no-EMA	A3 – Many-hot only	0.8375	0.9563	0.7005	Chỉ thêm nhãn many-hot.
Ablation no-EMA	P1 – Gaussian only	0.8432	0.9436	0.7519	Tăng ClipShots nhưng giảm BBC.
Ablation no-EMA	P2 – Temperature only	0.8378	0.9570	0.6983	Gần như trùng control.
Ablation no-EMA	B1 – Focal + many-hot	0.8384	0.9559	0.7006	Tác động train-time nhỏ.
Ablation no-EMA	B4 – Temperature + Gaussian	0.8540	0.9570	0.7441	Cấu hình hậu xử lý được ưu tiên.
Ablation no-EMA	B5 – Full candidate no-EMA	0.8542	0.9551	0.7409	Focal + many-hot + hậu xử lý.
Calibration CV	A0 – AutoShot baseline, 5-fold CV	0.8443	0.9538	0.7881	Honest 5-fold CV; baseline mạnh nhất trên ClipShots.

Còn tiếp ở trang sau

Bảng B.3: Bảng đầy đủ tất cả thực nghiệm (tiếp theo)

Nhóm	Thực nghiệm / protocol	SHOT	BBC	Clip-Shots	Ghi chú
Calibration ceiling	A0 – AutoShot baseline, tune trên test	0.8475	0.9561	0.7896	Mức trần lạc quan; không dùng làm deploy honest.
Calibration CV	A1 – Phase2 control, 5-fold CV	0.8540	0.9631	0.7575	Honest 5-fold CV; Phase2 mạnh trên SHOT/BBC.
Calibration ceiling	A1 – Phase2 control, tune trên test	0.8540	0.9631	0.7599	Mức trần lạc quan; không dùng làm deploy honest.
Calibration CV	B5 – Phase2 đầy đủ, 5-fold CV	0.8539	0.9584	0.7555	Honest 5-fold CV; Phase2 mạnh trên SHOT/BBC.
Calibration ceiling	B5 – Phase2 đầy đủ, tune trên test	0.8550	0.9603	0.7607	Mức trần lạc quan; không dùng làm deploy honest.
EMA full fine-tune	A – Phase 1 raw	0.8412	0.9554	0.7648	Baseline raw trong EMA study.
EMA full fine-tune	B – Phase 1 + Gaussian	0.8477	0.9515	0.7899	Gaussian hậu xử lý rất mạnh trên ClipShots.
EMA full fine-tune	D-EMA, alpha=0.999	0.8417	0.9604	0.7860	Fine-tune toàn model + EMA.
EMA full fine-tune	D-noEMA control	0.8371	0.9494	0.7638	Fine-tune toàn model, tắt EMA.